

Minería de Datos

Construcción de Cubos OLAP

Data Warehouse Sintético

Equipo: PELONES LLG

Integrantes: Alvaro Lechuga Vecino, Teodoro Gómez Santillan, Kahlid Liconá Ramírez

Profesor: María de los Ángeles Cosío León

Fecha: 06/07/2026

1. Objetivos

1.1 Objetivo General

Construir y explotar un Cubo OLAP a partir de un Data Warehouse generado automáticamente con datos sintéticos de interacciones en redes sociales sobre equipos de fútbol durante 2023, aplicando conceptos de modelado dimensional (esquema en estrella) y operaciones OLAP (Roll-up, Drill-down, Slice, Dice y Pivot) para responder preguntas de negocio con evidencia cuantitativa.

1.2 Objetivos Específicos

- Comprender la estructura de un Data Warehouse, identificando la tabla de hechos (FACT_INTERACCIONES) y las tablas de dimensión (DIM_TIEMPO, DIM_PAIS, DIM_CIUADAD, DIM_RED, DIM_EQUIPO).
- Construir un modelo en estrella estableciendo jerarquías dentro de cada dimensión (p. ej. Año → Trimestre → Mes en DIM_TIEMPO).
- Explotar el Cubo OLAP mediante las cinco operaciones básicas: Roll-up, Drill-down, Slice, Dice y Pivot.
- Formular ocho consultas de negocio e interpretar sus resultados en términos comerciales/deportivos.
- Elaborar un informe técnico estructurado, con visualizaciones que respalden cada hallazgo.

2. Introducción

2.1 ¿Qué es Business Intelligence?

Business Intelligence (BI) es el conjunto de estrategias, procesos, arquitecturas y herramientas tecnológicas que permiten transformar datos operativos dispersos en información consolidada y en conocimiento útil para la toma de decisiones estratégicas. Incluye actividades como la integración de datos (ETL), el almacenamiento analítico (Data Warehouse), la explotación multidimensional (OLAP) y la visualización (dashboards).

2.2 ¿Qué es un Data Warehouse?

Un Data Warehouse es un repositorio centralizado, orientado al análisis, que integra datos históricos provenientes de una o varias fuentes. Sus características principales, según Inmon (2005), son:

- Orientado a temas: se organiza alrededor de procesos de negocio (en este caso, interacciones sociales por equipo de fútbol), no de aplicaciones transaccionales.
- Integrado: los datos provienen de distintas fuentes (redes sociales, catálogos de equipos, geografía) y se homogenizan en un formato y unidades consistentes.
- No volátil: una vez cargado un registro en el DW, no se actualiza ni se borra; solo se agregan nuevos periodos.
- Variable en el tiempo: conserva el histórico completo (aquí, los 365 días de 2023) para permitir análisis de tendencia y estacionalidad.

2.3 ¿Qué es un Cubo OLAP?

Un Cubo OLAP (Online Analytical Processing) es una estructura de datos multidimensional que organiza la información del Data Warehouse en ejes de análisis (dimensiones) y valores agregables (medidas), permitiendo consultas analíticas rápidas sin recalcularse desde el detalle transaccional. Sus componentes son:

- Celdas: contienen las medidas, por ejemplo el total de interacciones para una combinación específica de Tiempo, País, Ciudad, Red y Equipo.

- Dimensiones: son los ejes de análisis (Tiempo, País, Ciudad, Red Social, Equipo).
- Jerarquías: niveles de agregación dentro de cada dimensión (p. ej. Año → Trimestre → Mes, o Liga → País → Equipo).

2.4 Contexto del Laboratorio

El laboratorio utiliza un generador de datos sintéticos (generar_dataset.py, incluido en el Anexo A) que produce un Data Warehouse con información simulada —pero estadísticamente realista— sobre interacciones en redes sociales relacionadas con equipos de fútbol durante el año 2023. El generador introduce sesgos deliberados (mayor actividad en países con gran afición futbolera, mayor actividad los fines de semana, mayor uso de Twitter/Instagram/TikTok) para que el ejercicio de exploración OLAP tenga patrones interpretables, en vez de ruido puramente uniforme.

3. Generación del Data Warehouse

3.1 Comando de Generación

```
python generar_dataset.py --seed 4587 --registros 3000
```

3.2 Parámetros Utilizados

Parámetro	Valor
Semilla (seed)	4587
Número de registros (tabla de hechos)	3,000
Fecha de generación	2026-07-06
Periodo cubierto (DIM_TIEMPO)	01/ene/2023 – 31/dic/2023 (365 días)

3.3 Archivos Generados

Archivo	Registros	Descripción
DIM_TIEMPO.csv	365	Un registro por día de 2023, con jerarquía Año/Trimestre/Mes/Día de la semana.
DIM_PAIS.csv	15	Catálogo de países con jerarquía Continente → Región → País.
DIM_CIUDAD.csv	32	Ciudades asociadas a cada país (llave foránea id_pais).
DIM_RED.csv	5	Catálogo de redes sociales con jerarquía Tipo → Red Social.
DIM_EQUIPO.csv	20	Catálogo de equipos de fútbol con jerarquía Liga → País → Equipo.
FACT_INTERACCIONES.csv	3,000	Tabla de hechos: llaves foráneas a las 5 dimensiones + medidas (interacciones, alcance, compartidos, respuestas, ratio_compartidos) + atributos degenerados (sentimiento, hashtag).

4. Exploración del Data Warehouse

4.1 Descripción de Dimensiones


Archivo	Descripción
DIM_TIEMPO	id_tiempo (PK), fecha, anio, trimestre (T1-T4), mes, nombre_mes, dia_semana.
DIM_PAIS	id_pais (PK), continente, region, pais.
DIM_CIUDAD	id_ciudad (PK), id_pais (FK), pais, ciudad.
DIM_RED	id_red (PK), tipo, red_social.
DIM_EQUIPO	id_equipo (PK), liga, pais, equipo.
FACT_INTERACCIONES	id_fact (PK), id_tiempo/id_pais/id_ciudad/id_red/id_equipo (FK), sentimiento, hashtag, interacciones, alcance, compartidos, respuestas, ratio_compartidos.

4.2 Estadísticas Básicas

Métrica	Valor
Total de interacciones	970,875
Promedio por registro	323.62
Máximo de interacciones	6,703
Mínimo de interacciones	4
Sentimiento más común	Positivo (44.1% de los registros)
Red con más interacciones	Twitter (257,618 interacciones)

5. Modelo Estrella

5.1 Diagrama del Modelo



5.2 Preguntas de Análisis

- 1. ¿Cuál es la tabla de hechos?** FACT_INTERACCIONES, porque concentra las medidas cuantitativas del proceso de negocio (interacciones, alcance, compartidos, respuestas) y se relaciona con todas las dimensiones mediante llaves foráneas.
- 2. ¿Cuántas dimensiones existen?** Cinco: DIM_TIEMPO, DIM_PAIS, DIM_CIUADAD, DIM_RED y DIM_EQUIPO.
- 3. ¿Qué medidas contiene la tabla de hechos?** interacciones (SUM), alcance (AVG), compartidos (SUM), respuestas (SUM) y ratio_compartidos (DIV = compartidos/interacciones), definidas en la sección 6.2.
- 4. ¿Cuáles son las claves foráneas?** id_tiempo, id_pais, id_ciudad, id_red e id_equipo, cada una referenciando la llave primaria de su tabla de dimensión correspondiente.

5.3 Lista de Verificación del Modelo

Criterio	Sí	No
Se identificó correctamente la tabla de hechos	X	
Se identificaron todas las dimensiones	X	
Se establecieron las relaciones entre tablas	X	
Se dibujó correctamente el modelo estrella	X	

5.4 Preguntas de Análisis

Después de indagar en funcionamiento del método OLAP, llegamos a la conclusión que para integrarlo al proyecto principal necesitamos una pregunta para resolver este documento.

¿Qué combinaciones de País, Equipo y Red Social concentran el mayor volumen de interacciones durante 2023, y qué patrones (día de la semana, sentimiento predominante, tipo de red) explican esa concentración, con el fin de orientar dónde y cuándo invertir esfuerzo de contenido digital?

¿Para qué nos sirve OLAP en este caso?

Un cubo OLAP nos permite responder esta pregunta sin tener que escribir una consulta distinta cada vez que cambia el ángulo de análisis. En lugar de eso, disponemos de una sola estructura multidimensional que se puede explorar de cinco formas complementarias:

- Roll-up, para saber si la actividad es estable o estacional a lo largo del año (por trimestre), antes de invertir en una campaña de largo plazo.
- Drill-down, para pasar de una categoría general de red social (p. ej. "video corto") a la red específica (TikTok) y decidir en qué plataforma concreta enfocar el presupuesto.
- Slice, para aislar el comportamiento de un solo país o equipo cuando el objetivo es una campaña local (p. ej. solo España).
- Dice, para cruzar dos o más condiciones a la vez (p. ej. México y último trimestre) cuando la decisión de negocio depende de varios factores simultáneos.
- Pivot, para comparar visualmente varios países contra varias redes sociales en una sola tabla y detectar de un vistazo dónde está la combinación más rentable.

6. Construcción del Cubo OLAP

6.1 Dimensiones y Jerarquías

Dimensión	Jerarquía 1	Jerarquía 2	Jerarquía 3
Tiempo	Año	Trimestre	Mes
País	Continente	Región	País
Ciudad	País	Ciudad	-
Red Social	Tipo	Red Social	-
Equipo	Liga	País	Equipo

6.2 Medidas del Cubo


Medida	Agregación	Descripción
Total Interacciones	SUM	Suma total de interacciones (me gusta + comentarios + reacciones).
Alcance Promedio	AVG	Alcance promedio por publicación (personas que vieron el contenido).
Total Compartidos	SUM	Número total de veces que el contenido fue compartido.
Ratio Compartidos	DIV	Compartidos / Interacciones — porcentaje de interacciones que derivan en un compartido.
Total Respuestas	SUM	Número total de respuestas/comentarios recibidos.

7. Operaciones OLAP

7.1 Roll-up (Agregación)

Descripción: subir en la jerarquía de la dimensión Tiempo, pasando de Mes a Trimestre.

```
SELECT
  {[Measures].[Total Interacciones]} ON COLUMNS,
  {[Tiempo].[Trimestre].Members} ON ROWS
FROM [Cubo Interacciones]
WHERE [Tiempo].[Anio].&[2023]
```




Trimestre	Total Interacciones
T1	226,265
T2	257,978
T3	233,040
T4	253,592

Interpretación: el volumen de interacciones se mantiene relativamente estable a lo largo del año (variación de $\pm 6.6\%$ entre trimestres), con un pico en T2 (abril-junio) y un segundo repunte en T4 (octubre-diciembre). Esto es consistente con el calendario futbolístico, que concentra fases decisivas de ligas y torneos en esos periodos, generando mayor conversación en redes sociales.

7.2 Drill-down (Profundización)

Descripción: bajar en la jerarquía de la dimensión Red Social, pasando de Tipo a Red Social (ejemplo con el tipo 'Microblogging').

```
SELECT
  {[Measures].[Total Interacciones]} ON COLUMNS,
  {[Red Social].[Tipo].&[Microblogging].Children} ON ROWS
FROM [Cubo Interacciones]
```




Tipo	Red Social	Total Interacciones
Microblogging	Twitter	257,618
Imagen y video corto	Instagram	250,117
Video corto	TikTok	212,284
Red social generalista	Facebook	129,155
Video largo	YouTube	121,701

Interpretación: al profundizar del nivel 'Tipo' al nivel 'Red Social' se confirma que dentro de la categoría Microblogging, Twitter concentra el 100% de las interacciones (es la única red de ese tipo en el catálogo), y que en conjunto los formatos de imagen/video corto (Instagram + TikTok + Twitter) dominan sobre el video largo (YouTube), reflejando el consumo de contenido futbolístico en formatos breves y de alta frecuencia.

7.3 Slice (Rebanada)

Descripción: filtrar por un valor específico en la dimensión País (Slice = España).

```
SELECT
  {[Measures].[Total Interacciones]} ON COLUMNS,
  {[Equipo].[Equipo].Members} ON ROWS
FROM [Cubo Interacciones]
WHERE [País].[Nombre].&[Espana]
```




Resultado (Top 5 de 20 equipos): Real Madrid 27,455 · FC Barcelona 17,775 · Atlético Madrid 14,835 · Manchester City 4,660 · Palmeiras 4,019.

Interpretación: entre los aficionados que publican desde España, el 'Real Madrid' concentra claramente el mayor volumen de interacciones (27,455), seguido por el FC Barcelona y el Atlético Madrid; los tres equipos españoles dominan la conversación local, mientras que equipos extranjeros (Manchester City, Palmeiras) aparecen con menor peso, probablemente por seguidores expatriados o fans internacionales del club.

7.4 Dice (Dado)

Descripción: filtrar por múltiples valores en diferentes dimensiones (País = México AND Trimestre = T4).

```
SELECT
  {[Measures].[Total Interacciones]} ON COLUMNS,
  {[Equipo].[Equipo].Members} ON ROWS
FROM [Cubo Interacciones]
WHERE ([País].[Nombre].&[Mexico], [Tiempo].[Trimestre].&[T4])
```




Resultado (Top 5): Cruz Azul 6,317 · Club América 4,807 · Chivas Guadalajara 3,332 · Juventus 1,950 · Boca Juniors 1,720.

Interpretación: al acotar simultáneamente por país y periodo, se observa que Cruz Azul superó a Club América en interacciones generadas desde México durante el último trimestre de 2023, lo que sugiere un evento o resultado deportivo relevante para ese equipo en ese periodo (p. ej. un título, un fichaje o una polémica) que impulsó la conversación digital por encima de su rival tradicional.

7.5 Pivot (Rotación)

Descripción: intercambiar el orden de las dimensiones en la visualización (Países en filas, Redes Sociales en columnas).

```
SELECT
  {[Red Social].[Nombre].Members} ON COLUMNS,
  {[País].[Nombre].Members} ON ROWS
FROM [Cubo Interacciones]
WHERE [Measures].[Total Interacciones]
```



País \ Red	Twitter	Instagram	Facebook	TikTok	YouTube
España	22,394	25,140	13,373	21,947	14,519
México	34,958	35,442	12,956	22,521	14,050
Argentina	44,682	36,520	19,773	27,206	13,353

Interpretación: al rotar el cubo para comparar países contra redes sociales, Argentina muestra el mayor volumen absoluto en casi todas las redes (destaca en Twitter e Instagram), lo cual es consistente con la intensidad de la cultura futbolera argentina en redes sociales; Facebook es, en los tres países, la red con menor interacción relativa, reforzando la tendencia generacional hacia plataformas más visuales (Instagram/TikTok) y de texto breve (Twitter).


8. Consultas de Negocio

A continuación se muestran las 8 consultas de negocio solicitadas, cada una con su consulta MDX equivalente, el resultado obtenido sobre el cubo materializado y su interpretación de negocio.

8.2 Pregunta 1: Equipo con Mayor Interacción

¿Qué equipo de fútbol generó más interacciones en redes sociales?

```
SELECT {[Measures].[Total Interacciones]} ON COLUMNS,
       {[Equipo].[Equipo].Members} ON ROWS
FROM [Cubo Interacciones]
```



Resultado: Boca Juniors (68,917), seguido de River Plate (66,942), Club América (60,208), Flamengo (58,126) y Palmeiras (53,959).

Interpretación: los dos grandes clubes argentinos (Boca Juniors y River Plate) encabezan el ranking global, superando a equipos históricamente más mediáticos como Real Madrid o Barcelona. Esto refleja el peso combinado de una afición muy activa digitalmente y el sesgo de mayor actividad asignado a los mercados de habla hispana en el dataset; en un análisis real convendría normalizar por número de seguidores para distinguir 'más interacción absoluta' de 'mayor engagement relativo'.

8.3 Pregunta 2: País Más Activo

¿Cuál país generó más publicaciones en redes sociales?


```
SELECT {[Measures].[Conteo Publicaciones]} ON COLUMNS,
       {[País].[Nombre].Members} ON ROWS
FROM [Cubo Interacciones]
```

País	Publicaciones
México	381
Brasil	366
Argentina	360
Inglaterra	344
España	334

Interpretación: México encabeza el número de publicaciones (381), ligeramente por encima de Brasil y Argentina. Es un resultado esperable dado el peso poblacional y el fuerte consumo de redes sociales en el mercado mexicano, uno de los mercados prioritarios definidos en el generador sintético.

8.4 Pregunta 3: Red Social Más Activa


¿Qué red social tuvo mayor número de interacciones?



Resultado: Twitter (257,618), Instagram (250,117), TikTok (212,284), Facebook (129,155), YouTube (121,701).
Interpretación: Twitter y Instagram concentran el 52% del total de interacciones, confirmando que el contenido futbolístico breve y visual domina la conversación; Facebook y YouTube, orientados a formatos más largos o comunidades de mayor edad, quedan rezagados.

8.5 Pregunta 4: Día con Mayor Actividad

¿Qué día de la semana tuvo mayor actividad?




Resultado: Domingo (750 publicaciones), Sábado (673), Viernes (424); el resto de días entre 247 y 325.

Interpretación: el fin de semana concentra más del 47% de toda la actividad, coincidiendo con los días en que se juegan la mayoría de los partidos de liga; esto valida el supuesto de diseño de que la actividad en redes sociales sigue el calendario de partidos y sugiere que cualquier estrategia de contenido o publicidad debería concentrarse en sábado-domingo.

8.6 Pregunta 5: Sentimiento Predominante

¿Qué sentimiento predominó en las interacciones?



Resultado: Positivo 44.1% (1,323 registros), Neutro 31.0% (931), Negativo 24.9% (746).

Interpretación: el sentimiento positivo predomina, lo cual es típico en comunidades de aficionados que celebran a su equipo; sin embargo, una cuarta parte de las publicaciones son negativas, un umbral que en un entorno de monitoreo real (reputación de marca/equipo) ya ameritaría una alerta y análisis de causa raíz (p. ej. crisis deportiva, arbitrajes polémicos, resultados adversos).

8.7 Pregunta 6: Combinación País-Red Social

¿Qué combinación País-RedSocial tuvo mayor interacción?

País	Red Social	Interacciones
Argentina	Twitter	44,682
Argentina	Instagram	36,520
Inglaterra	TikTok	35,907
México	Instagram	35,442
México	Twitter	34,958

Interpretación: la combinación Argentina-Twitter es la celda más caliente del cubo, lo que sugiere que cualquier campaña dirigida a la afición argentina debería priorizar esa red por sobre las demás; nótese que Argentina aparece dos veces entre las 5 combinaciones principales, reforzando que es el mercado de mayor intensidad relativa en el dataset.

8.8 Pregunta 7: Hashtag Más Utilizado

¿Qué hashtag fue más utilizado en las publicaciones?

Hashtag	Publicaciones
#Mundial2026	664
#VamosSeleccion	483
#FutbolTotal	427
#GoleoElEquipo	335
#DiaDePartido	305

Interpretación: #Mundial2026 domina claramente (22% de todas las publicaciones), confirmando que la proximidad del torneo funciona como eje narrativo transversal a clubes y países, por encima incluso de hashtags específicos de equipo o de jornada.

8.9 Pregunta 8: Ciudad con Más Publicaciones

¿Qué ciudad generó más publicaciones?

Ciudad	Publicaciones
Buenos Aires	194
São Paulo	189
Río de Janeiro	177
Manchester	177
Londres	167

Interpretación: Buenos Aires lidera como ciudad individual, coherente con el peso de Argentina detectado en las preguntas 1 y 6; las ciudades brasileñas y británicas completan el top 5, mostrando que la actividad se concentra en un puñado de grandes centros urbanos con fuerte tradición futbolística, más que distribuirse uniformemente entre las 32 ciudades del catálogo.

9. Conclusiones

1. ¿Qué aprendiste sobre los Cubos OLAP? Que un cubo OLAP no es más que una vista pre-agregada y multidimensional de una tabla de hechos, optimizada para responder preguntas analíticas ('¿cuánto?', '¿quién más?', '¿cuándo?') sin necesidad de escribir cada vez una consulta SQL compleja con múltiples JOIN y GROUP BY; las cinco operaciones (Roll-up, Drill-down, Slice, Dice, Pivot) son en el fondo distintas formas de moverse por las jerarquías y filtros de las dimensiones sobre la misma estructura de datos subyacente.

2. ¿Por qué es mejor un Cubo que una tabla plana para el análisis de datos? Porque la tabla plana obligaría a recalcular manualmente cada agregación y cada combinación de filtros con una consulta distinta, mientras que el cubo organiza de antemano las dimensiones y jerarquías, de modo que subir o bajar de nivel (Roll-up/Drill-down) o cambiar el eje de análisis (Pivot) es una operación declarativa y consistente; además, separar hechos de dimensiones evita la duplicación de atributos descriptivos (nombre de equipo, liga, país) en cada fila de detalle, reduciendo el tamaño y el riesgo de inconsistencias.

3. ¿Qué dificultades encontraste durante la construcción del cubo? El entorno de trabajo no contaba con un servidor OLAP real (SSAS/Mondrian) para ejecutar MDX en vivo, por lo que fue necesario materializar el cubo como una vista desnormalizada en pandas y reproducir cada operación MDX con su equivalente en groupby/pivot_table; otro reto fue diseñar sesgos realistas en el generador sintético (mayor actividad en fin de semana, mercados con más afición) para que los resultados de las consultas de negocio tuvieran un patrón interpretable en vez de ser ruido uniforme.

4. ¿Qué operación OLAP consideras más útil y por qué? El Dice, porque combina múltiples condiciones de distintas dimensiones (por ejemplo País y Trimestre) en una sola vista, que es exactamente el tipo de pregunta que hace un analista de negocio real ('¿cómo se comportó este mercado en este periodo?'); el Slice y el Roll-up son más simples, y el Pivot es principalmente una ayuda de visualización más que un cambio en el contenido analítico.

5. ¿Qué recomendaciones de negocio darías basado en los resultados obtenidos? (a) Concentrar la publicación de contenido patrocinado en sábado y domingo, que representan el 47% de la actividad; (b) priorizar Twitter e Instagram sobre Facebook y YouTube en la asignación de presupuesto de medios; (c) diseñar campañas específicas para el mercado argentino (más intenso en Twitter) y el mexicano (más intenso en Instagram); (d) dar seguimiento cercano al 25% de sentimiento negativo detectado, investigando su causa raíz por equipo/periodo antes de que escale; y (e) aprovechar el hashtag #Mundial2026 como eje transversal de campañas, dado que concentra uno de cada cinco mensajes del dataset.

10. Anexos

A. Scripts Utilizados

Script generador del Data Warehouse:

```
#!/usr/bin/env python3
"""
generar_dataset.py
-----
Generador de datos sinteticos para el Data Warehouse "Interacciones en Redes
Sociales sobre equipos de futbol - 2023".

Produce el esquema en estrella descrito en la practica:
    DIM_TIEMPO.csv
    DIM_PAIS.csv
    DIM_CIUADAD.csv
    DIM_RED.csv
    DIM_EQUIPO.csv
    FACT_INTERACCIONES.csv

Uso:
    python generar_dataset.py --seed 4587 --registros 3000
"""

import argparse
import os
import numpy as np
import pandas as pd
from datetime import date, timedelta

# -----
# 1. Argumentos de linea de comandos
# -----
parser = argparse.ArgumentParser(description="Generador de Data Warehouse sintetico")
parser.add_argument("--seed", type=int, default=4587, help="Semilla del generador aleatorio")
parser.add_argument("--registros", type=int, default=3000, help="Numero de registros en la tabla de hechos")
parser.add_argument("--out", type=str, default="../data", help="Carpeta de salida de los CSV")
args = parser.parse_args()

rng = np.random.default_rng(args.seed)
os.makedirs(args.out, exist_ok=True)

FECHA_GENERACION = date.today().isoformat()

# -----
# 2. DIM_PAIS (continente, region, pais)
# -----
paises_data = [
    # continente, region, pais
    ("America", "Norteamerica", "Mexico"),
    ("America", "Norteamerica", "Estados Unidos"),
    ("America", "Norteamerica", "Canada"),
    ("America", "Sudamerica", "Argentina"),
    ("America", "Sudamerica", "Brasil"),
    ("America", "Sudamerica", "Uruguay"),
    ("Europa", "Europa Occidental", "Espana"),
    ("Europa", "Europa Occidental", "Francia"),
    ("Europa", "Europa Occidental", "Inglaterra"),
    ("Europa", "Europa Occidental", "Alemania"),
    ("Europa", "Europa del Sur", "Italia"),
    ("Europa", "Europa del Sur", "Portugal"),
```

```

    ("Africa", "Norte de Africa", "Marruecos"),
    ("Asia", "Asia Oriental", "Japon"),
    ("Asia", "Asia Occidental", "Arabia Saudita"),
]
dim_pais = pd.DataFrame(paises_data, columns=["continente", "region", "pais"])
dim_pais.insert(0, "id_pais", range(1, len(dim_pais) + 1))
dim_pais.to_csv(f"{args.out}/DIM_PAIS.csv", index=False)

# -----
# 3. DIM_CIUADAD (depende de DIM_PAIS)
# -----
ciudades_por_pais = {
    "Mexico": ["Ciudad de Mexico", "Guadalajara", "Monterrey"],
    "Estados Unidos": ["Nueva York", "Los Angeles", "Miami"],
    "Canada": ["Toronto", "Vancouver"],
    "Argentina": ["Buenos Aires", "Cordoba"],
    "Brasil": ["Sao Paulo", "Rio de Janeiro"],
    "Uruguay": ["Montevideo"],
    "Espana": ["Madrid", "Barcelona", "Sevilla"],
    "Francia": ["Paris", "Marsella"],
    "Inglaterra": ["Londres", "Manchester"],
    "Alemania": ["Berlin", "Munich"],
    "Italia": ["Roma", "Milan"],
    "Portugal": ["Lisboa", "Oporto"],
    "Marruecos": ["Casablanca", "Rabat"],
    "Japon": ["Tokio", "Osaka"],
    "Arabia Saudita": ["Riad", "Jeda"],
}
filas_ciudad = []
for _, row in dim_pais.iterrows():
    for ciudad in ciudades_por_pais.get(row["pais"], []):
        filas_ciudad.append((row["id_pais"], row["pais"], ciudad))
dim_ciudad = pd.DataFrame(filas_ciudad, columns=["id_pais", "pais", "ciudad"])
dim_ciudad.insert(0, "id_ciudad", range(1, len(dim_ciudad) + 1))
dim_ciudad.to_csv(f"{args.out}/DIM_CIUADAD.csv", index=False)

# -----
# 4. DIM_RED (tipo, red_social)
# -----
redes_data = [
    ("Microblogging", "Twitter"),
    ("Imagen y video corto", "Instagram"),
    ("Video largo", "YouTube"),
    ("Red social generalista", "Facebook"),
    ("Video corto", "TikTok"),
]
dim_red = pd.DataFrame(redes_data, columns=["tipo", "red_social"])
dim_red.insert(0, "id_red", range(1, len(dim_red) + 1))
dim_red.to_csv(f"{args.out}/DIM_RED.csv", index=False)

# -----
# 5. DIM_EQUIPO (liga, pais, equipo)
# -----
equipos_data = [
    ("Liga MX", "Mexico", "Club America"),
    ("Liga MX", "Mexico", "Chivas Guadalajara"),
    ("Liga MX", "Mexico", "Cruz Azul"),
    ("La Liga", "Espana", "Real Madrid"),
    ("La Liga", "Espana", "FC Barcelona"),
    ("La Liga", "Espana", "Atletico Madrid"),
    ("Premier League", "Inglaterra", "Manchester City"),
    ("Premier League", "Inglaterra", "Liverpool"),
    ("Premier League", "Inglaterra", "Arsenal"),
    ("Serie A", "Italia", "Juventus"),

```

```

("Serie A", "Italia", "AC Milan"),
("Bundesliga", "Alemania", "Bayern Munich"),
("Bundesliga", "Alemania", "Borussia Dortmund"),
("Ligue 1", "Francia", "Paris Saint-Germain"),
("Liga Argentina", "Argentina", "Boca Juniors"),
("Liga Argentina", "Argentina", "River Plate"),
("Brasileirao", "Brasil", "Flamengo"),
("Brasileirao", "Brasil", "Palmeiras"),
("Primeira Liga", "Portugal", "Benfica"),
("Saudi Pro League", "Arabia Saudita", "Al Nassr"),
]
dim_equipo = pd.DataFrame(equipos_data, columns=["liga", "pais", "equipo"])
dim_equipo.insert(0, "id_equipo", range(1, len(dim_equipo) + 1))
dim_equipo.to_csv(f"{args.out}/DIM_EQUIPO.csv", index=False)

# -----
# 6. DIM_TIEMPO (todo el ano 2023, con jerarquia Anio -> Trimestre -> Mes)
# -----
inicio = date(2023, 1, 1)
fin = date(2023, 12, 31)
dias = pd.date_range(inicio, fin, freq="D")

dias_semana_es = ["Lunes", "Martes", "Miercoles", "Jueves", "Viernes", "Sabado", "Domingo"]

dim_tiempo = pd.DataFrame({
    "fecha": dias.date,
})
dim_tiempo["anio"] = dias.year
dim_tiempo["trimestre"] = "T" + dias.quarter.astype(str)
dim_tiempo["mes"] = dias.month
dim_tiempo["nombre_mes"] = dias.month_name()
dim_tiempo["dia_semana"] = [dias_semana_es[d] for d in dias.weekday]
dim_tiempo.insert(0, "id_tiempo", range(1, len(dim_tiempo) + 1))
dim_tiempo.to_csv(f"{args.out}/DIM_TIEMPO.csv", index=False)

# -----
# 7. FACT_INTERACCIONES
# -----
N = args.registros

sentimientos = ["Positivo", "Negativo", "Neutro"]
sentimiento_probs = [0.45, 0.25, 0.30]

hashtags = [
    "#Mundial2026", "#VamosSeleccion", "#FutbolTotal", "#GoleoElEquipo",
    "#DiaDePartido", "#FanaticoDelFutbol", "#RumboAlMundial", "#Campeones",
]

# Damos mas peso a paises/equipos con mayor base de aficionados (Mexico,
# Espana, Argentina, Brasil e Inglaterra) para simular un mercado real,
# en vez de una distribucion uniforme (evita un dataset "de juguete").
pesos_pais = np.ones(len(dim_pais))
paises_top = ["Mexico", "Espana", "Argentina", "Brasil", "Inglaterra"]
for i, p in enumerate(dim_pais["pais"]):
    if p in paises_top:
        pesos_pais[i] = 3.0
pesos_pais = pesos_pais / pesos_pais.sum()

id_pais_muestra = rng.choice(dim_pais["id_pais"], size=N, p=pesos_pais)

# Ciudad coherente con el pais elegido (evita inconsistencias FK)
id_ciudad_muestra = np.empty(N, dtype=int)
ciudad_por_pais_idx = {pid: dim_ciudad[dim_ciudad["id_pais"] == pid]["id_ciudad"].values
    for pid in dim_pais["id_pais"]}

```

```

for i, pid in enumerate(id_pais_muestra):
    opciones = ciudad_por_pais_idx[pid]
    id_ciudad_muestra[i] = rng.choice(opciones)

# Equipo con mayor probabilidad si coincide el pais del aficionado (sesgo realista)
id_equipo_muestra = np.empty(N, dtype=int)
equipo_por_pais_idx = {pid: dim_equipo.merge(dim_pais, on="pais")[
    dim_equipo.merge(dim_pais, on="pais")["id_pais"] == pid]["id_equipo"].values
    for pid in dim_pais["id_pais"]}
todos_los_equipos = dim_equipo["id_equipo"].values
for i, pid in enumerate(id_pais_muestra):
    locales = equipo_por_pais_idx.get(pid, np.array([]))
    if len(locales) > 0 and rng.random() < 0.6:
        id_equipo_muestra[i] = rng.choice(locales)
    else:
        id_equipo_muestra[i] = rng.choice(todos_los_equipos)

# Red social: TikTok/Instagram/Twitter mas usadas que YouTube/Facebook
pesos_red = np.array([0.28, 0.26, 0.12, 0.12, 0.22]) # Twitter, Insta, YouTube, FB, TikTok
id_red_muestra = rng.choice(dim_red["id_red"], size=N, p=pesos_red)

# Tiempo: mas actividad en fin de semana (dias de partido) -> sesgo por dia_semana
pesos_dia = dim_tiempo["dia_semana"].map({
    "Lunes": 0.10, "Martes": 0.08, "Miercoles": 0.10, "Jueves": 0.10,
    "Viernes": 0.14, "Sabado": 0.24, "Domingo": 0.24,
}).values
pesos_dia = pesos_dia / pesos_dia.sum()
id_tiempo_muestra = rng.choice(dim_tiempo["id_tiempo"], size=N, p=pesos_dia)

sentimiento_muestra = rng.choice(sentimientos, size=N, p=sentimiento_probs)
hashtag_muestra = rng.choice(hashtags, size=N, p=[0.22, 0.16, 0.14, 0.12, 0.10, 0.10, 0.09, 0.07])

# Medidas numericas (distribuciones asimetricas tipo redes sociales: lognormal)
interacciones = rng.lognormal(mean=5.2, sigma=1.1, size=N).astype(int) + 1
alcance = (interacciones * rng.uniform(8, 15, size=N)).astype(int)
compartidos = (interacciones * rng.uniform(0.05, 0.25, size=N)).astype(int)
respuestas = (interacciones * rng.uniform(0.02, 0.18, size=N)).astype(int)

fact = pd.DataFrame({
    "id_tiempo": id_tiempo_muestra,
    "id_pais": id_pais_muestra,
    "id_ciudad": id_ciudad_muestra,
    "id_red": id_red_muestra,
    "id_equipo": id_equipo_muestra,
    "sentimiento": sentimiento_muestra,
    "hashtag": hashtag_muestra,
    "interacciones": interacciones,
    "alcance": alcance,
    "compartidos": compartidos,
    "respuestas": respuestas,
})
fact.insert(0, "id_fact", range(1, len(fact) + 1))
fact["ratio_compartidos"] = (fact["compartidos"] / fact["interacciones"]).round(4)

fact.to_csv(f"{args.out}/FACT_INTERACCIONES.csv", index=False)

# -----
# 8. Resumen de ejecucion
# -----
print("=" * 60)
print("GENERACION DE DATA WAREHOUSE SINTETICO COMPLETADA")
print("=" * 60)
print(f"Semilla utilizada      : {args.seed}")
print(f"Registros solicitados   : {args.registros}")

```

```

print(f"Fecha de generacion      : {FECHA_GENERACION}")
print(f"Carpeta de salida        : {os.path.abspath(args.out)}")
print("-" * 60)
for nombre, df in [
    ("DIM_TIEMPO", dim_tiempo), ("DIM_PAIS", dim_pais),
    ("DIM_CIUADAD", dim_ciudad), ("DIM_RED", dim_red),
    ("DIM_EQUIPO", dim_equipo), ("FACT_INTERACCIONES", fact),
]:
    print(f" {nombre:<22} {len(df):>6} registros")
print("=" * 60)

```

B. Consultas MDX / pandas Adicionales

Ejemplo de consulta adicional: Top 3 equipos por país (más allá de las 8 solicitadas), útil para un futuro dashboard de comparación entre clubes rivales del mismo mercado.

```

# Equivalente pandas de una consulta MDX de "Top N por dimensión padre"
cubo.groupby(["pais","equipo"])[ "interacciones"].sum() \
    .groupby(level=0, group_keys=False) \
    .nlargest(3)

```

C. Checklist de Entregables

Criterio	Sí	No
El generador produjo correctamente los archivos CSV	X	
Se identificó la tabla de hechos	X	
Se definieron todas las dimensiones	X	
Se construyó el esquema estrella	X	
Se ejecutó la operación Roll-up	X	
Se ejecutó la operación Drill-down	X	
Se ejecutó la operación Slice	X	
Se ejecutó la operación Dice	X	
Se ejecutó la operación Pivot	X	
Se respondieron las consultas de negocio	X	
Se elaboraron las conclusiones	X	