



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 4

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

Glosario de Términos Técnicos

Término	Definición
Corpus	Colección estructurada de documentos de texto (en este caso, artículos de noticias) reunida para su análisis computacional.
GDELT (Global Database of Events, Language, and Tone)	Base de datos abierta de eventos y monitoreo de medios globales, con una API pública de búsqueda de artículos (DOC API 2.0).
NewsAPI	Servicio comercial con tier gratuito que expone un endpoint (/v2/everything) para buscar artículos de noticias por palabra clave, idioma y rango de fechas.
HTTP 429 (Too Many Requests)	Código de respuesta HTTP que indica que el cliente ha excedido el límite de peticiones permitido en un periodo de tiempo (rate limiting).
Throttling	Restricción progresiva o intermitente en la velocidad de respuesta de un servicio, usada para controlar el volumen de tráfico de un cliente.
Query / consulta de búsqueda	Cadena de texto (con operadores como comillas para frase exacta, sourcelang, domainis) que se envía a una API de búsqueda para filtrar resultados.
Tier gratuito (free tier)	Nivel de acceso sin costo de un servicio API, generalmente con límites de peticiones diarias, antigüedad de datos o volumen de resultados.
Deduplicación	Eliminación de artículos repetidos que aparecen en más de una consulta, para no inflar artificialmente el tamaño del corpus.
URL-encoding	Codificación de caracteres especiales (como tildes/acentos) dentro de una URL para que el servidor los interprete correctamente.

Objetivo de la Sesión

Construir el corpus de noticias bilingüe (español/inglés) sobre el Mundial 2026 que servirá de insumo para el preprocesamiento (Sesión 5) y el clustering temático (Sesión 6).

Evaluar con evidencia empírica —no por conveniencia— si las fuentes candidatas de recuperación de información (GDELT y NewsAPI) son viables para el alcance bilingüe del proyecto.

Definir de forma explícita el alcance del corpus (bilingüe, no histórico, respetando límites de un tier gratuito) como una decisión de diseño documentada, no como una limitación oculta.

Herramientas y Tecnologías Utilizadas

- **GDELT 2.0 DOC API:** primera fuente candidata evaluada; API pública de búsqueda de artículos por palabra clave, idioma y fecha.
- **NewsAPI (newsapi.org), tier Developer:** fuente finalmente aceptada; endpoint /v2/everything, límite de 100 peticiones/día y ~1 mes de antigüedad.
- **requests (Python):** librería usada para todas las peticiones HTTP a ambas APIs, con parámetros pasados vía diccionario (no concatenación manual de strings) para un URL-encoding correcto.
- **Carga de credenciales por archivo local:** newsapi_key.txt (excluido de Git vía .gitignore) o variable de entorno NEWSAPI_KEY; la key nunca se escribe en la terminal ni se pega en el chat.
- **JSON:** formato de almacenamiento del corpus crudo, con metadatos explícitos (fuente, fecha de construcción, rango de fechas, queries usadas, distribución por idioma).

Roadmap — Qué se Hizo

Paso 1. Probar GDELT — rondas v1 a v3

- v1: queries en inglés y español para "Mundial 2026". Resultado: HTTP 429 en inglés, y 0 artículos (pero 200 OK) en español.
- v2: se amplió la prueba en inglés con frase exacta "World Cup 2026" — resultado exitoso: 50 artículos devueltos, confirmando que la API sí funciona técnicamente.
- v3: se probaron variantes por dominio (marca.com, as.com) y consultas generales en español ("Mundial España campeón") — resultado: HTTP 429 en las consultas sin filtro de idioma, y nuevamente 0 artículos (200 OK) en las que sí filtraban sourcelang:spa.

Paso 2. Probar GDELT — ronda v4 (prueba controlada final)

- Se diseñó una prueba mínima de una sola petición, esperando 10-15 minutos desde la última corrida, para descartar que el throttling contaminara el diagnóstico.
- Se probó la hipótesis de que el 0 en español se debía a codificación incorrecta de tildes en versiones anteriores, enviando la query con acentos reales vía el parámetro 'params' de requests (URL-encoding automático y correcto).
- Resultado: seguía devolviendo 0 artículos en español, con 200 OK. Se descartó la hipótesis de codificación.
- Decisión: rechazo formal de GDELT como fuente, con evidencia acumulada de 4 rondas de pruebas (persistencia de rate limiting + cero cobertura real en español).

Paso 3. Probar NewsAPI como reemplazo

- Se implementó el mismo patrón seguro de carga de API key (archivo local / variable de entorno) desde la primera prueba.
- Prueba inicial con bajo volumen (20 resultados por query) para no consumir cuota antes de confirmar viabilidad.
- Resultado: 200 OK tanto en español como en inglés, con artículos relevantes y bien fechados — a diferencia de GDELT.
- Decisión: aceptada como fuente única para el corpus de la Sesión 4.

Paso 4. Construir el corpus real

- 4 queries en total (es_mundial2026, es_seleccion_espanola, en_worldcup2026, en_fifa_worldcup), muy por debajo del límite de 100 peticiones/día.
- Rango de 28 días hacia atrás, dentro del límite del tier gratuito (~1 mes).
- Se guardó título, descripción y un fragmento truncado a ~200 caracteres (no el artículo completo), decisión deliberada por derechos de autor y por el alcance de "corpus para minería de texto".

- Resultado final: 330 artículos únicos tras deduplicación — 177 en español, 153 en inglés — guardados en corpus_mundial2026_raw.json con metadatos completos.

Problemas Encontrados y Cómo se Resolvieron

Problema	Causa raíz	Solución aplicada	Evidencia / verificación
GDELT devuelve HTTP 429 de forma persistente en varias de las pruebas.	Rate limiting del servicio ante múltiples peticiones seguidas durante las rondas de diagnóstico (v1-v3).	Se rediseñó la prueba final (v4) como una sola petición mínima, con espera de 10-15 minutos antes de ejecutarla, para aislar el diagnóstico del propio throttling.	v4 se ejecutó una sola vez y devolvió 200 OK, permitiendo un diagnóstico limpio del problema real (cobertura en español, no rate limiting).
GDELT devuelve 0 artículos en español pese a que el inglés sí funciona (50 resultados con "World Cup 2026").	Hipótesis inicial: posible error de codificación de tildes/acentos en las queries anteriores (v1-v3 usaban términos sin caracteres especiales bien codificados).	Se construyó una prueba controlada (v4) enviando la query con tildes reales, dejando que requests hiciera el URL-encoding automáticamente vía el parámetro 'params' (no concatenación manual de string).	El resultado siguió siendo 0 artículos con 200 OK, descartando la hipótesis de codificación y confirmando que es una limitación real de cobertura de fuentes en español.
Riesgo de exponer la API key de NewsAPI en texto plano (terminal o chat).	Práctica insegura común: pegar la key directamente en el código o en una conversación para pruebas rápidas.	Se implementó desde el primer script de prueba un patrón de carga segura: variable de entorno NEWSAPI_KEY o archivo local newsapi_key.txt, excluido de Git vía .gitignore.	La key nunca aparece en el historial de comandos ni en el código versionado; verificado en test_api.py y corpus_FIFA_WC.py.
El tier gratuito de NewsAPI limita a 100 peticiones/día y ~1 mes de antigüedad de artículos.	Restricción comercial del servicio, no negociable en un proyecto académico sin presupuesto.	Se acotó el alcance del proyecto para encajar en el límite: solo 4 queries totales, ventana de 28 días, cobertura del torneo actual (no histórica).	El corpus final se construyó muy por debajo del límite diario, sin necesidad de un plan de pago.

Tomas de Decisiones Destacadas

Rechazar GDELT solo tras evidencia acumulada de 4 rondas de pruebas, no tras el primer fallo

El equipo no descartó GDELT en la primera prueba con HTTP 429. Se investigó de forma incremental (v1 a v4) hasta aislar la causa real —cobertura estructuralmente nula en español, no un problema de codificación ni de throttling puntual— antes de declararla formalmente rechazada, siguiendo la exigencia de BRAI de rechazar con evidencia, no por suposición.

Definir el alcance del corpus alrededor de las limitaciones del tier gratuito, en vez de buscar un atajo

En lugar de intentar sortear el límite de NewsAPI (por ejemplo, con múltiples cuentas o scraping adicional), el equipo decidió que el proyecto se limitara a 4 queries, 28 días y contenido truncado, tratando esas restricciones como parte legítima del diseño del corpus.

Truncar el contenido a ~200 caracteres por decisión de alcance, no solo por limitación técnica

Aunque NewsAPI ya trunca el contenido en su tier gratuito, el equipo documentó explícitamente que esto es deseable y no solo tolerado: evita problemas de derechos de autor por reproducción extensa de artículos y es coherente con el objetivo real de la sesión (un corpus para minería de texto, no un archivo de artículos completos).

Cuadro Comparativo: Decisiones de la IA vs. Decisiones del Equipo

Nota metodológica: las columnas contrastan la primera hipótesis o el enfoque más obvio frente a la decisión final del equipo, documentada en los scripts y en el JSON de metadatos del corpus, conforme a la metodología BRAI.

Problema abordado	Qué propuso / sugirió la IA	Qué aceptó el equipo	Qué rechazó el equipo y por qué (evidencia)
Por qué GDELT devuelve 0 artículos en español mientras que en inglés sí funciona.	Hipótesis técnica más obvia y barata de probar primero: error de codificación de acentos/tildes en las queries anteriores.	Se aceptó probar esa hipótesis de forma controlada, construyendo una query con tildes reales y URL-encoding correcto vía el parámetro 'params'.	Se rechazó la hipótesis tras la prueba: el resultado siguió siendo 0 artículos con 200 OK, lo que llevó al equipo a concluir que el problema era de cobertura real de fuentes en español, no de codificación — evidencia documentada en el script v4.
Qué hacer ante el bloqueo HTTP 429 recurrente durante las pruebas de GDELT.	Enfoque automático típico: reintentar la petición inmediatamente o en un bucle corto hasta obtener una respuesta 200.	Se aceptó que hacían falta más intentos para obtener el diagnóstico completo.	Se rechazó reintentar en bucle: el equipo estableció explícitamente una regla de espera de 10-15 minutos entre ejecuciones y una sola petición mínima por prueba, tratando el 429 como una señal a respetar y no como un obstáculo a forzar.
Cuánto contenido de cada artículo almacenar en el corpus.	Enfoque esperable si se buscara maximizar información disponible: intentar obtener el texto completo del artículo (por ejemplo, scrapeando la URL de cada noticia además de consultar la API).	Se aceptó el título, la descripción y un fragmento corto (~200 caracteres) que ya entrega NewsAPI.	Se rechazó explícitamente ir a buscar el texto completo por scraping adicional: el equipo documentó que hacerlo generaría un riesgo de derechos de autor por reproducción extensa, y que no era necesario para el objetivo de minería de texto y clustering temático de las siguientes sesiones.