



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 7

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

1. Glosario de Términos Técnicos

Término	Definición
Serie temporal	Secuencia de observaciones de una variable, ordenadas cronológicamente (en este caso, artículos publicados por día).
BRAI	Bitácora de Razonamiento Asistido por IA. Metodología del curso que exige evidencia empírica para cada decisión técnica y documentación explícita de lo aceptado y lo rechazado.
Corpus	Conjunto de documentos de texto usado como base de análisis; en este proyecto, 330 artículos periodísticos recolectados vía NewsAPI (Sesión 4).
Cluster temático	Agrupación de artículos por similitud semántica, obtenida mediante embeddings en la Sesión 6 (3 temas: cobertura en cancha, política/negocios FIFA, narrativa de España campeona).
Sesgo de muestreo	Distorsión sistemática en los datos recolectados, causada por el método de selección (no por azar), que favorece a ciertos casos sobre otros.
sortBy=relevancy	Parámetro de NewsAPI que ordena los resultados por relevancia editorial respecto a la búsqueda, en lugar de por fecha de publicación.
totalResults	Campo de la respuesta de NewsAPI que indica el número total de artículos que cumplen el criterio de búsqueda, más allá de los que efectivamente se descargan.
Ventana móvil (rolling window)	Rango de fechas de acceso permitido por un plan de API, que se desplaza junto con la fecha real (por ejemplo, 'último mes desde hoy'), en vez de ser un rango fijo.
HTTP 426 / HTTP 429	Códigos de error HTTP. 426 indica que la petición está fuera del alcance permitido por el plan contratado; 429 indica que se alcanzó el límite de peticiones permitidas en el periodo.

2. Objetivo de la Sesión

Construir una serie temporal diaria a partir del corpus de noticias del Mundial 2026, identificar su patrón de comportamiento (tendencia, picos, decaimiento) y auditar la calidad y el posible sesgo de los datos subyacentes, antes de utilizarlos como insumo en las Sesiones 8 (Pronóstico) y 9 (Detección de Anomalías).

3. Herramientas y Tecnologías Utilizadas

- Python 3.14
- pandas — agregación y transformación temporal
- matplotlib — visualización de series
- requests — verificación puntual contra la API de NewsAPI
- NewsAPI (plan gratuito "Developer") — fuente de datos de cobertura mediática
- Insumos previos del proyecto: corpus_mundial2026_raw.json (Sesión 4) y clusters_tematicos_embeddings.json (Sesión 6)

4. Roadmap: Qué se Hizo

1. Se evaluó y se rechazó usar resultados deportivos (worldcup26.ir, StatsBomb) como fuente de la serie temporal: el torneo ya había concluido, por lo que esas fuentes son fotografías estáticas, no series que evolucionen en el tiempo.
2. Se decidió usar el campo fecha_publicacion del corpus de NewsAPI (Sesión 4) como fuente real de una serie temporal: volumen de cobertura mediática día a día.
3. Se construyó construir_series_temporales.py, que agrega el corpus por día y lo cruza por URL con la asignación de cluster temático de la Sesión 6 (100% de coincidencia en el cruce, sin pérdidas).
4. Se generó la serie diaria (28 días, del 10 de julio al 6 de agosto de 2026) y dos visualizaciones: volumen total diario y volumen diario desglosado por cluster temático.
5. Se identificó un pico claro el 19 y 20 de julio, coincidente con la fecha real de la final del Mundial 2026 (España 1-0 Argentina, tiempo extra), seguido de una caída sostenida tipo "ciclo noticioso".
6. Se detectaron dos días con cero artículos (27 de julio y 2 de agosto) y, siguiendo el principio BRAI de no asumir sin evidencia, se decidió verificarlos empíricamente en vez de interpretarlos directamente como ausencia real de noticias.
7. Se construyó verificar_dias_cero.py, que confirmó que sí existían cientos de artículos reales esos días (233 a 282 según la consulta) — el corpus original simplemente no los había capturado.
8. Se diagnosticó la causa raíz revisando el script original de la Sesión 4: usaba sortBy=relevancy junto con una sola página de 100 resultados, lo que favorece sistemáticamente al evento de mayor magnitud (la final) y desplaza a los artículos de días más tranquilos.
9. Se construyó medir_volumen_diario_newsapi.py para cuantificar ese sesgo día por día, usando el campo totalResults como medida de volumen real sin el sesgo de ordenamiento por relevancia.
10. La ejecución se vio limitada por dos restricciones del plan gratuito: una ventana móvil de 30 días (que dejó fuera de rango el 10-15 de julio) y un límite de 100 peticiones diarias (alcanzado el 1 de agosto). Se obtuvo cobertura verificada del 16 de julio al 1 de agosto (57% de la ventana total).
11. Con esos datos se calculó una correlación de 0.969 entre el volumen real y el conteo del corpus original, confirmando que la forma de la curva es confiable pese al sesgo de magnitud (tasa de captura promedio de apenas 1.63%).
12. Se descubrió que el 27 de julio es un caso distinto: 0% de tasa de captura (no solo baja, sino nula) frente a un rango de 0.7%-2.8% en el resto de los días verificados — una anomalía de captura real, no solo el sesgo general.
13. Por restricción de tiempo del entregable, se decidió conscientemente no perseguir la verificación del 2 de agosto, documentando la decisión explícitamente en vez de dejarla como un vacío sin explicar.

5. Problemas Encontrados y Soluciones

Problema	Causa	Solución aplicada
Dos días de la serie con 0 artículos (27 jul, 2 ago)	Desconocida al momento de construir la serie; podía ser ausencia real de noticias o falla de recolección.	Se construyó un script de verificación puntual contra NewsAPI en vez de asumir la causa sin evidencia.
Error HTTP 426 en la primera corrida de verificación	Se interpretó inicialmente como límite de cuota (429); en realidad es un error distinto: la fecha solicitada queda fuera del rango que permite el plan gratuito.	Se corrigió el script para distinguir 426 (fuera de ventana del plan, se documenta y se continúa) de 429 (límite real de peticiones, se detiene y se reanuda después).
El 10 al 15 de julio ya no eran verificables al momento de correr el script	El plan gratuito de NewsAPI solo permite consultar el último mes contando desde la fecha real de la petición, no desde que se construyó el corpus original; esa ventana ya se había desplazado hacia adelante.	Se documentó como limitación estructural y permanente del proyecto, no como error de ejecución.
Límite de 100 peticiones diarias alcanzado a mitad de la verificación de sesgo	Se necesitaban 112 peticiones (4 consultas × 28 días) para cubrir toda la ventana.	Se diseñó el script con guardado incremental (checkpoint/resume); ante la restricción real de tiempo del equipo, se decidió conscientemente cerrar con cobertura parcial (16 jul-1 ago) en vez de esperar a otro día.

6. Tomas de Decisiones Destacadas

- Rechazar la fuente de datos que sugería originalmente el temario (resultados deportivos) en favor de una serie realmente dinámica: el volumen de cobertura mediática.
- No asumir que "0 artículos" significa "no hubo noticias" — verificar empíricamente antes de interpretar, replicando el mismo estándar que el equipo ya había aplicado con GDELT en la Sesión 4.
- Medir el sesgo usando el campo `totalResults` de NewsAPI (más económico en cuota) en vez de descargar artículos completos, que hubiera sido redundante con el corpus que ya existe para fines de clustering.
- Aceptar conscientemente dejar el 2 de agosto sin verificar por restricción real de tiempo, documentando la decisión de forma explícita en vez de ocultar el vacío o fingir que se completó el análisis.

7. Comparación: Decisiones de la IA vs. Decisiones del Equipo Humano

La metodología BRAI del curso exige documentar explícitamente qué propuso la Inteligencia Artificial frente a cada problema, y qué decidió finalmente el equipo humano — incluyendo los casos en que ambas coincidieron y los casos en que no.

Aspecto / Problema	Qué propuso la IA	Qué decidió el equipo	Resultado
Qué fuente usar para la serie temporal	Propuso abandonar el temario original (resultados deportivos, ya estáticos) y usar el corpus de noticias como fuente dinámica real.	Aceptó el cambio de fuente propuesto, validando la justificación técnica presentada.	Serie temporal realmente aprovechable para las Sesiones 8 y 9, con continuidad respecto al trabajo de la Sesión 6.
Qué hacer con los días en cero	Propuso verificar empíricamente contra NewsAPI antes de interpretar, en vez de asumir.	Aceptó y ejecutó la verificación en su máquina, aportando la evidencia real (los logs de NewsAPI).	Se descubrió el sesgo de captura del corpus original y la anomalía específica del 27 de julio.
Alcance de la verificación del sesgo (28 días completos)	Propuso completar la ventana entera, con reintento al día siguiente si se agotaba la cuota diaria.	Decidió priorizar el tiempo disponible y cerrar con cobertura parcial (57%), dejando el 2 de agosto sin verificar.	Limitación documentada explícitamente, sin bloquear el avance del resto del proyecto.

8. Evidencia Visual



