



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 12

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

Glosario de Términos Técnicos

Término	Definición
Buscador semántico	Sistema de recuperación de información que compara el significado de una consulta y los documentos usando vectores de embeddings, en vez de coincidencia literal de palabras.
Embedding	Representación numérica (vector) de un texto que captura su significado, generada por un modelo de lenguaje entrenado; textos con significado similar tienen vectores cercanos.
Precision@5	Métrica de evaluación de buscadores: proporción de resultados relevantes entre los primeros 5 devueltos (relevantes encontrados / 5).
Ground truth	Conjunto de respuestas correctas o juicios de referencia (en este caso, relevancia de cada documento) contra el cual se evalúa un sistema; debe ser generado por criterio humano, no por otro modelo de IA, para evitar evaluación circular.
Juicio de relevancia	Evaluación humana, documento por documento, de si un resultado de búsqueda realmente responde a una consulta dada.
Modelo multilingüe (paraphrase-multilingual-MiniLM-L12-v2)	Modelo de embeddings entrenado para representar texto en múltiples idiomas en un mismo espacio vectorial, permitiendo comparar significado entre idiomas distintos.
Cosine similarity	Medida de similitud entre dos vectores basada en el ángulo entre ellos; valores cercanos a 1 indican alta similitud semántica.

Objetivo de la Sesión

Construir un buscador funcional comparando dos enfoques de recuperación de información -BM25 (léxico, construido en la Sesión 11) y embeddings semánticos multilingües (paraphrase-multilingual-MiniLM-L12-v2, calculados originalmente en la Sesión 6)- evaluados mediante Precision@5 sobre un juicio de relevancia humano, documento por documento.

Este objetivo incluyó un desvío metodológico no planeado pero valioso: detectar y corregir un juicio de relevancia inválido antes de aceptar cualquier métrica final, siguiendo el principio BRAI de verificar la evidencia antes de reportarla.

Herramientas y Tecnologías Utilizadas

- Python 3.x
- sentence-transformers (modelo paraphrase-multilingual-MiniLM-L12-v2)
- rank_bm25
- scikit-learn (cosine_similarity)
- pandas y matplotlib (resultados y gráficas)
- Hugging Face Hub (descarga del modelo de embeddings, solo accesible desde la máquina local del equipo)

Roadmap: Qué se Hizo

1. Se intentó generar los embeddings desde el entorno de Claude — bloqueado por falta de acceso a Hugging Face.
2. Se diseñó buscador_ir.py para ejecución local, combinando BM25 y búsqueda semántica sobre las mismas 10 consultas de la Sesión 11.
3. Se resolvieron errores de entorno (launcher de pip roto) para poder instalar dependencias.
4. Se ejecutó el script localmente, generando el CSV de resultados top-5 por motor y consulta.
5. Primer juicio de relevancia manual del equipo — detectado como inválido (mismo valor repetido por consulta).
6. Se generó una propuesta de re-juicio documento-por-documento con justificación explícita por parte de la IA.
7. Primera corrección del equipo — detectada como inconsistente mediante comparación automatizada contra el archivo original.
8. Segunda entrega del equipo (lista de valores 0/1) — confirmada como juicio final e intencional.
9. Cálculo de Precision@5 final y generación de la gráfica comparativa.

Problemas Encontrados y Cómo se Resolvieron

Problema encontrado	Cómo se resolvió
Generar embeddings semánticos requiere descargar el modelo paraphrase-multilingual-MiniLM-L12-v2 desde Hugging Face, dominio sin acceso desde el entorno de Claude.	El script buscador_ir.py se diseñó para ejecutarse en la máquina local del equipo, que sí tiene acceso a internet sin restricciones, siguiendo el mismo patrón ya usado en sesiones anteriores (Sesión 7, Sesión 10).
Error "Fatal error in launcher" al instalar dependencias con pip (mismo problema de la Sesión 10: pip.exe apuntaba a una instalación de Python 3.13 inexistente).	Se resolvió con <code>python -m pip install ...</code> en vez de pip directo.
El primer juicio de relevancia manual resultó inválido: las 5 filas de cada consulta/motor traían siempre el mismo valor (0,0,0,0,0 o 1,1,1,1,1), lo que estadísticamente indicaba que se evaluó "¿la consulta tiene cobertura en el corpus?" en vez de "¿este documento específico es relevante?".	Se detectó el patrón (Precision@5 idéntica de 0.5 en ambos motores, sin un solo resultado parcial) y se generó una propuesta de re-juicio documento por documento con justificación explícita, marcada claramente como borrador de IA pendiente de validación humana.
La primera "corrección" entregada por el equipo mantuvo el mismo error: el texto de justificación no cambió (seguía defendiendo el criterio original) pero el valor numérico se invirtió, generando contradicciones internas (ej. "es el artículo exacto sobre el documental" marcado como no relevante).	Se verificó automáticamente con un diff programático contra el archivo original, confirmando que las 25 filas cambiadas tenían el mismo texto de justificación sin actualizar. Se solicitó una segunda entrega por un método distinto (lista simple de valores) para descartar un error de edición de spreadsheet.




Figura 1. Precision@5 por consulta, BM25 vs. buscador semántico, con el juicio de relevancia final confirmado por el equipo. Resultado general: BM25 = 0.14, Semántico = 0.24.

Tomas de Decisiones Destacadas

- No aceptar una métrica de evaluación sospechosamente perfecta (0.5 vs 0.5 idéntica en las 10 consultas) sin investigar la causa — se prefirió detener el proceso y diagnosticar antes de reportar un resultado potencialmente inválido.
- Generar el juicio de relevancia propuesto por la IA con justificación textual explícita por documento, dejando expresamente marcadas las filas no verificables solo por título (11/100), para que el equipo supiera exactamente dónde enfocar su revisión.
- Verificar programáticamente (no solo "a ojo") que la corrección del equipo reflejara un cambio real de criterio, comparando contra el archivo original antes de aceptar el resultado como definitivo.
- Documentar en el minireporte final la inconsistencia detectada entre justificación y valor final como nota de transparencia, en vez de ocultarla, para que el equipo pueda explicarla en la defensa técnica si se les pregunta por un caso específico.

Cuadro Comparativo: Decisiones de la IA vs. Decisiones del Equipo Humano

Problema / Decisión	Propuesta de la IA	Decisión / Acción del equipo humano
Generar los embeddings semánticos para el buscador	Diseñar el script completo (BM25 + semántico) y explicar por qué debía ejecutarse localmente, dado que la IA no tiene acceso a Hugging Face desde su entorno.	Ejecutar el script en la máquina local, instalar las dependencias faltantes y resolver los errores de entorno (launcher de pip) para obtener los resultados reales.
Evaluar objetivamente qué buscador es mejor (BM25 vs. semántico)	Proponer un juicio de relevancia documento-por-documento o con justificación, tras detectar que el primer intento del equipo era inválido por evaluar a nivel de consulta completa.	Revisar la propuesta de la IA y ajustar 25 de 100 valores según su propio criterio, entregando el juicio final -tras dos intentos, uno con inconsistencias detectadas y corregidas- como decisión definitiva del equipo.
Confirmar si la segunda corrección era intencional o un error de edición	Comparar automáticamente el archivo nuevo contra el original y contra el intento anterior para verificar consistencia del patrón de cambios.	Confirmar explícitamente, por una vía independiente (lista simple de valores en vez de CSV), que los 25 cambios eran la decisión final e intencional del equipo.