



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 13

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

Glosario de Términos Técnicos

Término	Definición
API	Interfaz de Programación de Aplicaciones; permite que un programa solicite datos a un servicio externo (ej. NewsAPI, GitHub) de forma estructurada.
BRAI	Bitácora de Razonamiento Asistido por IA; metodología del curso que exige evidencia empírica para cada decisión técnica y documentación explícita de lo rechazado.
Correlación de Pearson (r)	Medida estadística entre -1 y 1 que indica qué tan fuerte y en qué dirección se relacionan linealmente dos variables. $r=0$ indica ausencia de relación lineal.
Cubo OLAP	Estructura de datos multidimensional que organiza información en dimensiones (ejes de análisis) y medidas (valores agregables), permitiendo consultas analíticas rápidas.
Dimensión / Tabla de hechos	En un modelo en estrella, la tabla de hechos concentra las medidas cuantitativas (ej. valor de mercado); las dimensiones aportan el contexto descriptivo (ej. selección, club, posición).
JSON / CSV	Formatos de intercambio de datos: JSON (JavaScript Object Notation) permite estructuras anidadas; CSV (Comma-Separated Values) es tabular plano.
Orquestador	Programa que ejecuta en orden una secuencia de scripts independientes, verificando insumos y resultados de cada etapa antes de continuar.
Preflight	Verificación previa a la ejecución real de un proceso, que confirma que todos los archivos e insumos necesarios existen antes de correr nada.
Rate limiting	Límite de solicitudes que un servicio externo impone por unidad de tiempo (ej. 50 solicitudes cada 12 horas en NewsAPI); al superarse, el servicio responde con error en vez de datos.
Roll-up / Drill-down / Slice / Dice / Pivot	Las cinco operaciones estándar de un cubo OLAP: subir de nivel de agregación, bajar de nivel, filtrar por un valor, filtrar por varios valores combinados, y rotar los ejes de análisis, respectivamente.
Validación de contenido	Verificación de que el resultado de un proceso es correcto en su contenido (ej. número de artículos > 0), no solo que el programa terminó sin error de código.

Objetivo de la Sesión


Unificar los dos pipelines de datos contruidos a lo largo del proyecto —minería de texto (Sesiones 4 a 12) y datos estructurados de jugadores y equipos (Fases 1 a 5)— en un solo sistema funcional. Esto implicó resolver los huecos de datos identificados, responder con evidencia empírica las tres preguntas de investigación originales del proyecto, construir un modelo dimensional (cubo OLAP) real que reemplazara el ejercicio previo con datos sintéticos, y automatizar la ejecución de principio a fin mediante un orquestador único, cumpliendo así con el "Producto 1: Sistema funcional" exigido por el curso.

Herramientas y Tecnologías Utilizadas

- Python 3.14 — biblioteca estándar (csv, json, pathlib, subprocess, urllib.request), sin dependencias externas para los scripts de análisis.
- openfootball/worldcup.json (GitHub) — fuente pública de resultados reales del Mundial 2026, sin autenticación ni límite de solicitudes.
- Datasets propios del proyecto: equipos_limpio.csv, jugadores_mundial_limpio.csv, leistungsdaten_parcial_limpio.csv, statsbomb_rendimiento_jugador_partido.csv.
- Verificación empírica vía búsqueda web: disponibilidad de datos StatsBomb 2026, plantillas oficiales 2025-26 de las 5 grandes ligas europeas (Wikipedia).
- subprocess (Python) — para la orquestación y ejecución encadenada de los 14 scripts del sistema.

Roadmap de la Sesión

- 1. Reverificación BRAI de la disponibilidad de datos StatsBomb del Mundial 2026 (resultado: no disponible, confirma decisión previa).
- 2. Captura de resultados reales del Mundial 2026 (104 partidos, 48 selecciones) mediante openfootball/worldcup.json.
- 3. Resolución de la Pregunta 1: correlación entre % de convocados en las 5 grandes ligas y rendimiento en el torneo.
- 4. Resolución de la Pregunta 2: correlación entre carga de partidos de club y rendimiento individual en Qatar 2022.
- 5. Resolución de la Pregunta 3: correlación entre rendimiento en club y rendimiento en el Mundial.
- 6. Construcción del cubo OLAP real (modelo en estrella + 5 operaciones) sobre los datos propios del proyecto.
- 7. Detección y corrección de un bug real en el mapeo de clubes utilizado en la Pregunta 1.
- 8. Construcción del orquestador único (pipeline_completo.py), con verificación previa, copia automática de insumos y validación de resultados antes de promoverlos.
- 9. Diagnóstico y corrección de los fallos reales detectados al ejecutar el pipeline completo por primera vez.
- 10. Selección documentada del "mayor problema técnico del proyecto" para la Bitácora BRAI.



* Elemento con limitación documentada (ver tabla de problemas)

Figura 1. Arquitectura integrada de los dos pipelines del proyecto y su convergencia en la Sesión 13.

Problemas Encontrados y Cómo se Resolvieron

#	Problema	Causa raíz	Solución aplicada
1	worldcup26.ir cambió de alcance	El repositorio, mantenido por un solo desarrollador, migró a cubrir clubes de Premier League/LaLiga en vez del Mundial; riesgo de continuidad ya anotado desde la Fase 1.	Sustitución por openfootball/worldcup.json, fuente pública sin autenticación, verificada con el resultado real de la final del torneo.
2	20 de 88 clubes de las 5 grandes ligas mal escritos en el mapeo manual	Mapeo hecho a mano sin verificación automática contra los nombres reales del dataset (faltaba "FC"/"AFC", acentos distintos).	Verificación automática cruzando cada nombre contra los 454 clubes únicos reales; la correlación de la Pregunta 1 cambió de $r=0.684$ a $r=0.770$.
3	Porteros con valores absurdos en la métrica de rendimiento ofensivo	Para porteros, la columna "goles" de leistungsdaten representa goles recibidos, no anotados (limitación ya documentada en la Fase 5).	Exclusión explícita de porteros de esa métrica específica antes de calcular la correlación de la Pregunta 3.
4	Desfase temporal de ~4 años entre variables de las Preguntas 2 y 3	StatsBomb Open Data solo tiene publicado el Mundial de Qatar 2022; el Mundial 2026 aún no se libera, según se reverificó empíricamente.	Documentado como limitación explícita en los propios scripts; los resultados se presentan como aproximación, no como prueba directa de la hipótesis original.
5	3 de 11 etapas obligatorias del pipeline fallaron en la primera corrida real	Cada script de sesiones anteriores asumía que sus archivos de entrada vivían físicamente junto a él, no en una ubicación compartida.	El orquestador copia automáticamente los insumos configurados a la carpeta de cada script antes de ejecutarlo.
6	Riesgo real de sobrescribir el corpus válido (330 artículos) con uno vacío	NewsAPI respondió con error 429 (cuota agotada) sin que el script de captura lo reportara como fallo (código de salida 0).	Validador de contenido que bloquea la promoción de una salida vacía o inválida a su ubicación canónica, sin importar el código de salida del script.
7	Bug de ruta real en construir_indice.py (Sesión 11)	El script busca el corpus preprocesado un nivel de carpeta más arriba de donde realmente está guardado.	Copia adicional del archivo en la ubicación donde el script (con su bug) lo busca, sin modificar el código original ya entregado.
8	Script y archivo intermedio de la Sesión 7 no localizables	Pérdida del archivo construir_series_temporales.py y de series_diarias.csv entre sesiones de trabajo, probablemente por no descargarse antes de cerrar una sesión.	Documentado como limitación aceptada; los resultados derivados (Sesiones 8 y 9) se conservan, pero no son reproducibles desde cero.

Tomas de Decisiones Destacadas

- Se descartó forzar una conclusión sobre "fatiga por carga de partidos" (Pregunta 2) pese a la presión de cerrar la pregunta con un hallazgo llamativo; se documentó como resultado inconcluso, distinguiendo explícitamente "no hay efecto" de "no se pudo medir el efecto con los datos disponibles".
- Se decidió no reescribir los 12 scripts de sesiones anteriores para resolver el problema de rutas inconsistentes; en su lugar se construyó una capa de orquestación externa que se adapta al comportamiento real de cada script, preservando el trabajo ya validado en semanas previas.
- Se amplió el alcance del sistema final más allá del pipeline de minería de texto original, integrando también los datasets de jugadores y equipos y una capa de análisis OLAP real, tras una decisión explícita del equipo.
- Se priorizó la validación del contenido de una salida (no solo el código de retorno de un script) como criterio de éxito de cada etapa del pipeline, tras detectar que un script puede "tener éxito" técnicamente sin producir un resultado útil.
- Se seleccionó la falta de reproducibilidad del pipeline —no el bug de datos más llamativo— como el mayor problema técnico del proyecto, por ser el hallazgo más amplio y estructural, con múltiples causas raíz documentadas de forma independiente.

Comparativo: Decisiones de la IA vs. Decisiones del Humano

Problema	Propuesta / acción de la IA	Decisión del humano	Resultado / reflexión
Fuente de resultados reales del Mundial 2026	Verificó el estado actual de worldcup26.ir, detectó el cambio de alcance del repositorio, y propuso y validó openfootball/worldcup.json con 3 pruebas de consistencia interna.	Aceptó la fuente propuesta sin modificaciones.	Datos verificados de 104 partidos y 48 selecciones, con validación cruzada del campeón real.
Alcance del sistema de Sesión 13	Presentó la ambigüedad detectada en los archivos del proyecto como pregunta explícita con opciones, sin asumir una respuesta por sí sola.	Decidió expandir el alcance para incluir también jugadores, equipos y el cubo OLAP.	Cambio sustancial de plan que reorganizó el resto de la sesión hacia un sistema más completo.
Mapeo de clubes de las 5 grandes ligas	Primera versión: mapeo manual rápido sin verificación exhaustiva contra los datos reales (origen del bug de 20 errores).	No intervino en esta etapa; aceptación implícita del primer resultado entregado.	La propia IA detectó y corrigió el error en una revisión posterior, no el equipo humano.
Interpretación del resultado inconcluso de la Pregunta 2	Insistió en documentar el resultado como "inconcluso" en vez de forzar una conclusión narrativa sobre fatiga por carga de partidos.	Aceptó la recomendación sin objeciones.	Se preservó el rigor metodológico por encima de un hallazgo más llamativo pero no sustentado.
Validación exhaustiva tras los primeros fallos del pipeline	Propuso diagnosticar y corregir cada fallo (rutas inconsistentes, dependencia faltante, bug de indexación) antes de continuar.	Decidió omitir la validación exhaustiva restante y asumir que el pipeline "está bien" para avanzar más rápido.	Se documentó como limitación aceptada del alcance de verificación, priorizando tiempo de equipo sobre cobertura completa.
Selección del "mayor problema técnico del proyecto"	Propuso y argumentó tres candidatos distintos, cada uno con evidencia cuantitativa de respaldo.	Aceptó la recomendación final de la IA sin proponer una alternativa propia.	Patrón a vigilar en la defensa técnica: el equipo podría ejercer más criterio propio en vez de validar recomendaciones ya elaboradas.