



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

Minería de Datos

Grupo: 09_02

Proyecto de Data Mining-Fifa WC2026

Nombre de los Alumnos: Alvaro Lechuga Vecino, Teodoro Gómez Santillan,
Alan Khalid Liconá Ramírez

Verificación de fuentes

Scripts de la verificación en:

StatsBomb Open Data

Qué probamos: Instalamos la librería oficial statsbombpy y escribimos un script para listar todo el catálogo de competiciones disponibles, confirmar si existían Mundiales anteriores, verificar si ya había datos del Mundial 2026, y extraer una muestra real de partidos y eventos para inspeccionar las columnas disponibles.

Qué encontramos: El catálogo tiene 80 competición-temporadas en total, incluyendo 7 Mundiales masculinos (1958 a 2022) y 2 femeninos. Confirmamos que no existe ninguna temporada "2026" todavía, esto era esperado, porque StatsBomb libera sus datos abiertos de un torneo después de que concluye, no durante. También notamos que la cobertura de ligas de clubes es desigual: por ejemplo, la Premier League solo tiene las temporadas 2003/04 y 2015/16, no temporadas recientes.

Problema que tuvimos: Ninguno técnico real. El script corrió sin errores tanto en el entorno de prueba como en nuestra propia máquina, y los resultados fueron idénticos en ambos casos (mismo total de competiciones, mismo partido de muestra, mismas 94 columnas de eventos). El único "problema" fue de diseño: el script tomaba automáticamente el Mundial más reciente ordenando alfabéticamente, lo cual agarraba el Mundial Femenino 2023 en vez de Qatar 2022 (el masculino más reciente). Lo dejamos documentado para no confundirnos después.

Decisión final: Aceptada como fuente principal, pero solo para datos históricos (benchmark con Qatar 2022). No nos sirve para el Mundial 2026 en curso porque, como ya explicamos, esos datos no se publican hasta que termine el torneo.

FBref

Qué probamos: Primero intentamos lo más simple: una petición HTTP directa con la librería requests y un User-Agent que describía honestamente nuestro proyecto académico.

Problema 1: Bloqueo inmediato con error 403 Forbidden, en la primera petición.

Cómo lo intentamos solucionar: Cambiamos el User-Agent para que imitara a un navegador real (Chrome en Windows), agregando también headers típicos de un navegador (Accept, Accept-Language, Referer).

Problema 2: Seguimos recibiendo 403, incluso con esos headers de navegador. Investigamos y encontramos la causa real: FBref migró su CDN a Cloudflare y activó un filtro de bots activo que detecta el "fingerprint" de la conexión TLS de la librería requests de Python, no es un tema de qué headers le pongamos, es que la librería misma se reconoce como no-navegador a otro nivel técnico.

Cómo lo intentamos solucionar: Cambiamos de herramienta a la librería soccerdata, que en lugar de usar requests simple, controla un navegador Chrome real de forma automatizada. La instalamos y la usamos para revisar qué ligas cubre nativamente.

Problema 3: Encontramos que soccerdata solo cubre 9 ligas de forma nativa (las 5 grandes europeas más algunas competiciones de selecciones), lo cual no amplía la cobertura que ya teníamos, solo resolvía el problema de acceso, no el de cobertura para selecciones fuera de Europa.

Problema 4: Al correr la prueba real (read_schedule()), el script se quedó colgado indefinidamente sin dar ningún resultado ni error. Investigamos y la causa probable es que soccerdata corre el navegador en modo invisible ("headless") por defecto, y Cloudflare frecuentemente detecta navegadores invisibles y los atrapa en una verificación que nunca se completa.

Cómo lo intentamos solucionar: Modificamos el script para forzar el navegador en modo visible (headless=False), para poder ver si aparecía algún reto de verificación que pudiéramos resolver manualmente.

Decisión final: Antes de seguir invirtiendo tiempo, hicimos un alto y comparamos qué necesitábamos realmente de FBref contra lo que ya teníamos confirmado en otras fuentes. Encontramos que Transfermarkt (que ya sabíamos accesible sin estos problemas) también ofrece partidos jugados, minutos, goles y asistencias por temporada en su sección de estadísticas de carrera (leistungsdaten). Como esto cubre exactamente lo que necesitábamos de FBref, decidimos descartar FBref por redundancia e inaccesibilidad, no tenía sentido seguir peleando con un bloqueo

estructural cuando ya teníamos la misma información disponible en una fuente sin esa barrera.

Transfermarkt

Qué probamos: Antes de escribir cualquier script, investigamos si Transfermarkt tenía las mismas protecciones anti-bot que FBref. Encontramos evidencia de que existen scrapers comerciales y de código abierto que la acceden con peticiones HTTP simples (sin necesidad de navegador), lo cual era una señal positiva. Para confirmarlo nosotros mismos, probamos el proyecto open-source transfermarkt-scraper, ejecutando su primer paso: obtener la lista de confederaciones.

Resultado del primer test: Funcionó perfecto, sin ningún bloqueo.

Problema: Al avanzar al segundo paso de la jerarquía (obtener países dentro de una confederación), recibimos 403 Forbidden en las 5 peticiones que se hicieron. Lo extraño es que era exactamente la misma URL base que sí había funcionado un paso antes. Probamos esa misma URL después con una petición manual (curl) y también nos dio 403, esto nos hizo confirmar que no era un rechazo de entrada, sino un bloqueo dinámico que se activó después de varias peticiones seguidas sin pausas entre ellas. Es decir, Transfermarkt no bloquea por quién eres, sino por qué tan rápido te comportas.

Cómo lo solucionamos: Escribimos nuestro propio script con pausas deliberadas de 5 segundos entre cada petición, en lugar de dejar que el crawler original disparara las peticiones tan rápido como pudiera. Con esa pausa, ambas pruebas (la página de confederaciones y la página de una selección nacional específica, Argentina) respondieron con código 200 sin ningún problema, y guardamos el HTML real para confirmar que la tabla de plantilla trae correctamente jugador, posición, edad, club actual (representado como escudo) y valor de mercado.

Decisión final: Aceptada como fuente principal, con la condición de que cualquier scraper que construyamos a partir de ahora tiene que incluir esas pausas desde el diseño inicial, no como algo que se agrega después si nos bloquean.

worldcup26.ir

Qué probamos: Antes de tocar código, investigamos qué tan oficial era esta fuente, porque el Entregable 1 la trataba al mismo nivel que las demás. Encontramos que es un proyecto personal de un desarrollador independiente en GitHub, no de FIFA, y que requiere autenticación con un token JWT, contrario a lo que habíamos asumido inicialmente sobre que era "completamente abierta".

Problema 1: Al intentar probar el endpoint de registro directamente desde la documentación interactiva (Swagger) del sitio, recibimos un error de "Failed to fetch". Investigando la URL que se generaba, descubrimos que Swagger estaba armando la petición hacia localhost:3050, es decir, la documentación pública estaba mal configurada y apuntando al servidor de desarrollo del propio creador, no al servidor real de producción.

Cómo lo solucionamos: Cambiamos el selector de servidor en Swagger a la opción de producción, pero seguía arrastrando el puerto y protocolo equivocados (<http://worldcup26.ir:3050> en vez de <https://worldcup26.ir>). En lugar de seguir peleando con esa interfaz mal configurada, optamos por construir la petición nosotros mismos, directamente desde la terminal con PowerShell, usando la URL correcta documentada en el repositorio oficial del proyecto.

Problema 2: Al intentar registrar un usuario por segunda vez con el mismo correo (porque ya lo habíamos registrado antes desde Swagger sin verlo confirmado), el servidor respondió correctamente con "User already exists", no era un error nuestro, sino la consecuencia lógica de que el primer registro sí había funcionado.

Cómo lo solucionamos: Usamos el endpoint de login (</auth/authenticate>) en lugar de registro, ya que el usuario ya existía. Esto nos devolvió el token JWT correctamente, y con él consultamos el endpoint de equipos, confirmando los 48 equipos del Mundial 2026 completos, organizados en 12 grupos, sin ningún hueco.

Decisión final: Aceptada, pero como fuente complementaria, la usamos solo para datos en vivo del torneo (calendario, resultados, equipos), nunca como fuente única o crítica de ninguna de nuestras 3 preguntas, dado que depende del mantenimiento de un solo desarrollador y ya encontramos evidencia directa de que su documentación pública tiene errores de configuración.

Sesgos y filtros

StatsBomb Open Data

Qué encontramos:

- 80 competición-temporadas en el catálogo gratuito.
- 7 Mundiales masculinos completos (1958–2022) y 2 femeninos (2019, 2023), cada uno con todos sus partidos desde fase de grupos hasta la final.
- Eventos de juego con un nivel de detalle alto: cada partido del Mundial trae entre 3,400 y 4,400 eventos individuales, con 94 columnas por evento, incluyendo exactamente lo que necesitamos para rendimiento individual (player_id, minute, shot_statsbomb_xg, pass_goal_assist, duel_outcome).

Qué descartamos:

- El Mundial 2026 en sí, no existe ninguna temporada "2026" en el catálogo, porque StatsBomb libera datos abiertos de un torneo después de que concluye, no durante.
- Las ligas de clubes como fuente de "temporada regular", aunque aparecen Bundesliga, La Liga, Premier League, etc. en el catálogo, la cobertura por temporada es tan desigual e incompleta (ej. Premier League solo tiene 2003/04 y 2015/16) que no es confiable para nuestra Pregunta 2/3. Por eso usamos Transfermarkt para esa parte, no StatsBomb.

Sesgos potenciales:

- **Sesgo de cobertura geográfica/temporal en ligas de clubes:** hay mucha más data de algunos países/años que de otros, lo cual ya descartamos como uso, pero es relevante dejarlo anotado.
- **Sesgo de "torneo único" como benchmark histórico:** vamos a usar Qatar 2022 como punto de comparación para nuestras 3 preguntas, pero un solo Mundial es una muestra de un torneo con condiciones específicas (formato de 32 equipos, no 48; sede en Medio Oriente con clima distinto; calendario de invierno europeo en vez de verano). Cualquier patrón que encontremos ahí podría no generalizar igual al Mundial 2026.
- **Sesgo en quién genera los datos:** los eventos de StatsBomb son etiquetados por analistas humanos siguiendo una metodología propia de la empresa. Decisiones subjetivas (qué cuenta como "duelo ganado", qué cuenta como "pase clave") están sujetas a esa metodología, no a un estándar universal, si comparamos con métricas de otra fuente, podrían no ser directamente equivalentes.

Transfermarkt

Qué encontramos:

- La jerarquía completa de selecciones nacionales (confederaciones, países, selecciones y jugadores), confirmada funcional con peticiones simples.
- Plantilla completa de una selección (probamos con Argentina): jugador, número, posición, fecha de nacimiento/edad, club actual (representado como escudo/ícono) y valor de mercado.
- La sección de estadísticas de carrera (leistungsdaten) que trae partidos jugados, goles, asistencias, tarjetas y minutos acumulados, desglosados por competición y temporada, esto es lo que cubre nuestras Preguntas 2 y 3 sin necesitar FBref.

Qué descartamos:

- El crawler original (transfermarkt-scraper) corriendo a su velocidad por defecto, lo descartamos porque generaba peticiones demasiado rápidas y nos bloqueaba (403) después de la primera petición exitosa. No descartamos la fuente, descartamos esa forma específica de usarla.
- Cualquier dato de eventos de juego a nivel de jugada (xG, duelos, pases clave), Transfermarkt simplemente no los tiene; sus métricas son acumulados de temporada (goles, asistencias, apariciones), no eventos individuales. Para eso seguimos dependiendo de StatsBomb.

Sesgos potenciales:

- **Sesgo de valoración subjetiva:** los valores de mercado que muestra Transfermarkt están basados en una combinación de opinión de expertos y contribución de usuarios, no en una transacción real verificada, si llegamos a usar valor de mercado como variable en algún momento, hay que tratarlo con cautela, no como un hecho objetivo.
- **Sesgo de cobertura por nivel de liga:** es razonable esperar que la profundidad de los datos (historial detallado, fotos, noticias asociadas) sea mayor para jugadores de ligas top europeas que para jugadores de ligas menos seguidas (ej. ligas asiáticas o africanas), esto podría afectar la calidad/completitud de los datos de jugadores convocados desde selecciones con menor presencia mediática.
- **Sesgo de "fuente única no oficial":** a diferencia de StatsBomb, Transfermarkt no es una fuente con metodología publicada y auditada, es una plataforma comercial que combina distintos métodos de captura de datos a lo

largo de los años, lo que puede introducir inconsistencias entre temporadas o ligas en cómo se cuenta algo (ej. criterios de "asistencia" pueden no ser 100% consistentes en el tiempo).

worldcup26.ir

Qué encontramos:

- Los 48 equipos completos del Mundial 2026, con código FIFA, bandera y grupo asignado (A–L), sin ningún hueco.
- Confirmamos que la API responde correctamente una vez resuelto el problema de autenticación y la URL correcta de producción.

Qué descartamos:

- Usarla como fuente para cualquier dato de rendimiento individual de jugador o estadística avanzada, no los tiene; solo expone equipos, grupos, calendario y marcadores.
- Usarla como fuente única o crítica para cualquiera de nuestras 3 preguntas de investigación, la limitamos a un rol de respaldo para datos básicos en vivo (calendario, resultados), dado el riesgo de continuidad que documentamos.

Sesgos potenciales:

- **Sesgo de fuente no oficial sin validación institucional:** al ser mantenida por un solo desarrollador independiente (no FIFA, no una empresa de datos deportivos), no hay garantía de un proceso de verificación de datos como el que tendría una fuente institucional, un error de captura no tendría el mismo control de calidad que en StatsBomb.
- **Sesgo de discontinuidad/cambio sin aviso:** ya encontramos evidencia directa de que su documentación pública tiene errores (la URL del servidor mal configurada). Esto sugiere que el proyecto puede tener otros problemas de mantenimiento no detectados, lo cual es un riesgo para la fase final del proyecto si el servicio cambia de estructura o deja de responder sin previo aviso durante el Mundial

Inventario de datos

StatsBomb Open Data

Elemento	Detalle
Origen y Fuente	Repositorio público de GitHub de StatsBomb (open-data), descargado mediante la librería oficial statsbombpy. Datos generados por analistas humanos de StatsBomb mediante etiquetado manual de eventos de video del partido.
Formato y Tipo	Semiestructurado/estructurado. Los datos llegan como JSON desde el repositorio y se convierten a DataFrames de pandas (tablas estructuradas) mediante la librería.
Metadatos	Catálogo de 80 competición-temporadas. Competición de uso: FIFA World Cup 2022 (competition_id 43, season_id 106), 64 partidos. Cada partido contiene entre 3,400 y 4,400 eventos, con 94 columnas por evento. Última actualización: dependiente del repositorio público de StatsBomb (no hay control nuestro sobre la frecuencia; no se han agregado datos del Mundial 2026 a la fecha de esta evaluación).
Calidad de los Datos	Alta completitud verificada a nivel de partido (los 64 partidos de Qatar 2022 están presentes, de fase de grupos a final) y a nivel de evento (columnas clave como player_id, minute, shot_statsbomb_xg, pass_goal_assist y duel_outcome presentes sin valores nulos en la muestra revisada). Cobertura desigual en ligas de clubes (ej. Premier League solo con 2003/04 y 2015/16), por lo que esas ligas se descartan del uso del proyecto.
Accesibilidad y Seguridad	Acceso público y gratuito, sin autenticación ni API key. No contiene datos personales sensibles más allá de nombres públicos de jugadores y estadísticas de desempeño deportivo público. Sin restricciones de privacidad aplicables.

Transfermarkt

Elemento	Detalle
Origen y Fuente	Plataforma comercial de Transfermarkt (transfermarkt.co.uk), accedida mediante scraping de páginas HTML públicas (peticiones HTTP directas). Datos capturados y mantenidos por el equipo editorial/comunidad de Transfermarkt.
Formato y Tipo	No estructurado en origen (HTML de páginas web), transformado a estructurado mediante extracción de tablas específicas (plantilla de equipo, estadísticas de carrera por jugador).
Metadatos	Jerarquía: Confederaciones → Países → Selecciones nacionales → Jugadores. Muestra probada: selección de Argentina, plantilla completa. Estadísticas de carrera (leistungsdaten) desglosadas por competición y temporada. Actualización: continua, ligada a cada ventana de transferencias y jornada de liga.
Calidad de los Datos	Plantilla de jugador completa y sin huecos en la muestra probada (jugador, posición, edad, club actual, valor de mercado). Riesgo de inconsistencia entre temporadas/ligas en criterios de captura (ej. definición de "asistencia"), dado que no sigue una metodología publicada y auditada como StatsBomb. Cobertura más profunda para ligas europeas top que para ligas de menor seguimiento mediático.
Accesibilidad y Seguridad	Acceso público sin autenticación, pero con bloqueo dinámico por comportamiento (rate-limiting) detectado tras peticiones rápidas consecutivas; mitigado con pausas mínimas de 5 segundos entre peticiones. No contiene datos personales sensibles regulados; toda la información es de carácter público y deportivo.

worldcup26.ir

Elemento	Detalle
Origen y Fuente	API REST de un proyecto independiente de código abierto (GitHub: rezarahiminia/worldcup2026), no afiliado a FIFA. Datos auto-recolectados/mantenidos por un solo desarrollador.
Formato y Tipo	Estructurado — respuestas en formato JSON con esquema fijo por endpoint (equipos, grupos, partidos, estadios).
Metadatos	48 equipos, 12 grupos (A–L) de 4 equipos cada uno. Campos por equipo: id, name_en, name_fa, fifa_code, iso2, flag, groups. Versión de API: 1.0.4 (OAS 3.0). Actualización: en vivo durante el torneo (calendario, resultados, marcadores).
Calidad de los Datos	Compleitud total verificada: 48/48 equipos presentes sin huecos, con campos consistentes. Se detectó un error de configuración en la documentación pública (Swagger apuntando a servidor de desarrollo en vez de producción), lo que sugiere posibles inconsistencias adicionales de mantenimiento no verificadas.
Accesibilidad y Seguridad	Requiere autenticación mediante registro/login y token JWT (válido 84 días). No contiene datos personales sensibles de terceros (solo información pública de equipos/torneo); el propio registro de usuario en la API sí crea una cuenta con correo y contraseña del equipo del proyecto, que debe gestionarse con cuidado básico de credenciales.