



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

Minería de Datos

Grupo: 09_02

Proyecto de Data Mining-Fifa WC2026

Nombre de los Alumnos: Alvaro Lechuga Vecino, Teodoro Gómez Santillan,
Alan Khalid Liconá Ramírez

Github de la limpieza:

<https://github.com/AlvaroKyux/FIFAWC-2026-Data-mining>

Fase 1: Extracción y limpieza de selecciones (worldcup26.ir)

Qué se hizo: Autenticación vía token JWT contra la API, descarga de los 48 equipos del Mundial 2026.

Técnicas de limpieza aplicadas:

- **Conversión de tipos:** el campo id llegaba como texto desde la API, se convirtió a número entero. Justificación: un identificador numérico debe tratarse como tal para poder ordenarlo, compararlo o usarlo como clave de cruce; dejarlo como texto puede generar errores de ordenamiento (ej. "10" antes de "2").
- **Normalización de texto:** se creó una versión del nombre de cada selección en mayúsculas y sin espacios extra (name_en_normalizado). Justificación: es la base para poder cruzar esta tabla contra Transfermarkt y StatsBomb más adelante, donde el mismo país puede aparecer con variaciones de mayúsculas o espacios.
- **Validación de consistencia de formato:** se verificó que el campo iso2 tuviera exactamente 2 caracteres en todos los registros. Justificación: esto reveló un caso real (Inglaterra y Escocia con código de 3 letras en vez de 2), que de otro modo hubiera pasado inadvertido y causado errores silenciosos en cruces futuros por país.

Fase 2: Extracción de plantillas (Transfermarkt)

Qué se hizo: Descubrimiento de las 48 selecciones vía la página de ranking FIFA, extracción de cada plantilla (jugador, posición, club, edad, valor de mercado).

Técnicas de limpieza aplicadas:

- **Extracción de información embebida en atributos HTML:** el club actual de cada jugador no estaba en texto plano, sino en el atributo title de la imagen del escudo del equipo. Justificación: sin extraer específicamente ese atributo, el campo "club" hubiera quedado vacío para los 1,248 jugadores; fue necesario identificar dónde vivía realmente el dato.
- **Deduplicación:** se eliminaron entradas repetidas de la misma selección (cada nombre de equipo aparecía dos veces en el listado del ranking, una por el ícono de bandera y otra por el texto). Justificación: sin deduplicar, el conteo de selecciones se habría inflado al doble de forma artificial.

Fase 3: Limpieza y filtrado de jugadores (Transfermarkt)

Qué se hizo: Filtrado de las plantillas extraídas a las 48 selecciones del Mundial, aplanado de la estructura a una tabla de jugadores.

Técnicas de limpieza aplicadas:

- **Filtrado por cruce de claves:** de 210 selecciones extraídas (todo el ranking FIFA), se filtraron solo las 48 relevantes, cruzando por el campo `seleccion_normalizada` contra la tabla de equipos de la Fase 1. Justificación: el alcance del proyecto son las 48 selecciones del Mundial, no las más de 200 que existen en el ranking completo; sin este filtro, el dataset tendría ruido fuera del alcance de las preguntas de investigación.
- **Separación de campos compuestos:** el campo de fecha de nacimiento llegaba en un solo texto con la edad entre paréntesis (ej. "02/09/1992 (33)"). Se separó en dos columnas independientes: `fecha_nacimiento` y `edad`. Justificación: la edad calculada en el momento del scraping queda desactualizada con el tiempo; separar la fecha real permite recalcular la edad en cualquier momento futuro del proyecto sin depender de un valor congelado.
- **Conversión de tipos (texto a fecha):** el campo de fecha se convirtió de texto a un tipo de fecha real. Justificación: permite operaciones como ordenar por edad o calcular diferencias de tiempo, que no son posibles si la fecha sigue siendo texto.
- **Conversión de tipos (texto a número monetario):** el valor de mercado llegaba como texto con símbolo de moneda y abreviación (ej. "€12.00m"). Se convirtió a un número en euros. Justificación: sin esta conversión, no se pueden hacer comparaciones, promedios ni rankings de valor de mercado entre jugadores.
- **Eliminación de duplicados por clave única:** se verificó que no hubiera dos registros con el mismo `player_id`. Justificación: un jugador duplicado distorsionaría cualquier conteo o promedio por selección.

Fase 4: Extracción y resumen de eventos (StatsBomb)

Qué se hizo: Descarga de los 64 partidos completos de Qatar 2022 con sus 234,637 eventos, construcción de una tabla resumen de rendimiento por jugador y partido.

Técnicas de limpieza aplicadas:

- **Manejo de valores faltantes según su naturaleza real:** 1,108 eventos no tenían jugador asociado (player_id nulo). Se identificó que estos correspondían a eventos estructurales del partido (inicio/fin de tiempo, cambios tácticos), no a errores de captura. Justificación: tratar este nulo como un error y eliminarlo habría sido incorrecto; se documentó como información legítima y se excluyó solo del análisis por jugador, sin descartarlo del dataset completo.
- **Agregación con manejo explícito de ceros:** al construir el resumen de goles y asistencias por jugador-partido, los jugadores sin esa estadística se completaron con 0 en vez de dejarlos vacíos. Justificación: un jugador que no anotó tiene 0 goles, que es un dato real y significativo, no una ausencia de información.
- **Verificación de rangos lógicos:** se comparó el resultado agregado de un partido conocido (Inglaterra vs Irán) contra el resultado real del torneo. Justificación: es una validación de calidad — confirma que la lógica de conteo de goles/asistencias produce números consistentes con la realidad, no solo que el código corre sin errores.

Fase 5: Estadísticas de carrera por jugador (Transfermarkt, leistungsdaten)

Qué se hizo: Extracción de partidos, goles, asistencias, tarjetas y minutos por competición y temporada, para los 1,248 jugadores.

Técnicas de limpieza aplicadas:

- **Distinción entre cero genuino y dato faltante:** el sitio usa el símbolo "-" para indicar que un jugador no participó en una competición. Se convirtió explícitamente ese símbolo a 0, no a un valor nulo. Justificación: "no jugó esa competición" es información real (cero partidos, cero goles), distinta de "no se pudo obtener el dato"; tratarlos igual habría introducido ambigüedad en cualquier análisis posterior de carga de partidos.
- **Limpieza de formato numérico con caracteres especiales:** los minutos jugados venían con coma de millares y apóstrofe (ej. "2,835"). Se eliminaron esos caracteres para obtener un número entero limpio. Justificación: un campo con texto mezclado no puede sumarse ni promediarse; era indispensable para calcular la "carga de partidos" que pide la Pregunta 2 del proyecto.
- **Registro explícito de fallos de extracción:** el único jugador cuya extracción falló se mantuvo en el dataset con una fila marcada como `extraccion_exitosa = False`, en vez de simplemente omitirlo. Justificación: esto permite cuantificar con precisión la cobertura real del dataset (80.9%) en lugar de que el dato faltante quede invisible.
- **Cruce con tabla de jugadores para contexto posicional:** se unió esta tabla con la de la Fase 3 para incorporar la posición de cada jugador. Justificación: el significado de "goles" en esta tabla cambia según la posición (en un portero corresponde a goles recibidos, no anotados); sin este cruce, sería imposible interpretar correctamente los números.

Productos generados:

equipos_limpio.csv: Las 48 selecciones del Mundial 2026, con código FIFA, código ISO2, grupo asignado (A–L) y nombre normalizado para cruces.

jugadores_mundial_limpio.csv: 1,248 jugadores convocados a las 48 selecciones, con nombre, posición, fecha de nacimiento, edad, club actual y valor de mercado.

leistungsdaten_parcial_limpio.csv: Estadísticas de carrera por competición y temporada (partidos, goles, asistencias, tarjetas, minutos) para 1,010 de los 1,248 jugadores (80.9% de cobertura).

statsbomb_rendimiento_jugador_partido.csv: Rendimiento individual por jugador y partido en el Mundial Qatar 2022 (xG, asistencias, duelos, pases, tiros, minutos), 1,996 filas.

tabla_mapeo_selecciones.csv: Tabla de referencia con el nombre de cada selección según worldcup26.ir, usada para cruzar consistentemente las demás fuentes por país.