



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 5

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

Glosario de Términos Técnicos

Término	Definición
Tokenización	Proceso de dividir un texto continuo en unidades discretas (tokens), típicamente palabras o signos de puntuación.
Lematización	Reducción de una palabra a su forma canónica de diccionario (lema) basada en un modelo entrenado y análisis gramatical (ej. "jugadores" → "jugador").
Stemming	Técnica más simple que la lematización: recorta sufijos de una palabra siguiendo reglas fijas, sin garantizar que el resultado sea una palabra real (ej. "jugando" → "jug").
POS tagging (etiquetado gramatical)	Asignación de una categoría gramatical (sustantivo, verbo, adjetivo...) a cada palabra de una oración; spaCy lo usa como apoyo para lematizar con precisión.
Stopwords	Palabras muy frecuentes y de bajo valor temático (artículos, preposiciones, etc.) que se descartan en tareas de minería de texto.
Boilerplate editorial	Texto repetitivo de origen no periodístico-temático que aparece en artículos web (créditos de foto, agencias de noticias, etiquetas de navegación del sitio).
spaCy	Librería de procesamiento de lenguaje natural con modelos entrenados por idioma (ej. es_core_news_sm, en_core_web_sm) que incluyen tokenización, POS tagging y lematización.
Pipeline de spaCy	Secuencia de componentes (tokenizador, POS tagger, parser, NER, lematizador) que procesan un texto; los componentes no necesarios pueden desactivarse para acelerar el procesamiento.
Modelo _sm / _md / _lg	Tamaños de modelo de spaCy (pequeño, mediano, grande); a mayor tamaño, mayor precisión pero mayor costo computacional y de descarga.

Objetivo de la Sesión

Transformar el corpus crudo de 330 artículos (Sesión 4) en un corpus limpio y lematizado, listo para el análisis de similaridad y clustering de la Sesión 6.

Justificar técnicamente cada decisión de la técnica de preprocesamiento —spaCy vs. NLTK, lematización vs. stemming— pensando en el impacto sobre el paso siguiente del pipeline, no solo en la sesión actual.

Documentar de forma transparente las limitaciones reales del modelo elegido, en vez de presentar un corpus "perfecto" que oculte sus imperfecciones.

Herramientas y Tecnologías Utilizadas

- **spaCy**: librería elegida para tokenización, POS tagging y lematización, con modelos entrenados por idioma.
- **es_core_news_sm / en_core_web_sm**: modelos pequeños de spaCy para español e inglés respectivamente, usados con los componentes NER y parser desactivados para acelerar el procesamiento.
- **NLTK (evaluada y descartada)**: librería clásica de NLP considerada inicialmente para esta sesión, según la plantilla del curso; descartada para lematización por las razones documentadas en el roadmap.
- **Expresiones regulares (re)**: usadas para eliminar el marcador de truncamiento de NewsAPI (ej. "... [+2066 chars]") y normalizar espacios antes de tokenizar.
- **JSON**: formato de entrada (corpus_mundial2026_raw.json) y salida (corpus_mundial2026_preprocesado.json) del pipeline de limpieza.

Roadmap — Qué se Hizo

Paso 1. Elegir spaCy sobre NLTK, con justificación técnica explícita

- NLTK usa un stemmer (Snowball) que para español no lematiza realmente, solo recorta sufijos de forma agresiva. spaCy trae modelos entrenados específicos por idioma con lematización real basada en diccionario + POS tagging, más precisa para un corpus bilingüe como este.

Paso 2. Elegir lematización sobre stemming, pensando en la Sesión 6

- El stemming puede fusionar palabras con significado distinto o dejar raíces que no son palabras reales, lo que degradaría la calidad semántica de los vectores usados después en TF-IDF/embeddings. La lematización conserva la forma canónica real de la palabra, preservando mejor el significado para el análisis de similitud.

Paso 3. Cargar los modelos de forma optimizada

- Se cargaron es_core_news_sm y en_core_web_sm deshabilitando los componentes de NER y parser (disable=["ner", "parser"]), que no se necesitan para este paso, acelerando el procesamiento sobre los 330 artículos.

Paso 4. Limpiar el texto antes de tokenizar

- Se eliminó el marcador de truncamiento propio del tier gratuito de NewsAPI (ej. "... [+1234 chars]"), URLs sueltas, y se normalizaron espacios — necesario porque ese marcador no es texto real del artículo, es un artefacto de la API que de no limpiarse contamina el corpus con un patrón falso muy frecuente.

Paso 5. Filtrar tokens y aplicar lematización

- Se conservaron solo tokens alfabéticos (se descartan números sueltos, puntuación y símbolos), con longitud mínima de 3 caracteres, que no fueran stopwords — usando la lista propia de spaCy por idioma, ampliada con términos deportivos genéricos de bajo valor temático.

Paso 6. Consolidar el corpus preprocesado

- Resultado final: 10,518 lemas totales sobre los 330 artículos (177 ES / 153 EN), guardados en corpus_mundial2026_preprocesado.json junto con la justificación metodológica embebida en los metadatos del archivo.

Problemas Encontrados y Cómo se Resolvieron

Problema	Causa raíz	Solución aplicada	Evidencia / verificación
El marcador de truncamiento de NewsAPI (ej. "... [+2066 chars]") se filtraba como si fuera texto real del artículo.	Es un artefacto generado por la API para indicar contenido cortado, no contenido periodístico real.	Se implementó una limpieza explícita con expresiones regulares antes de tokenizar, eliminando ese patrón y normalizando espacios.	Verificado directamente en el campo texto_limpio del corpus preprocesado: el marcador ya no aparece en los textos finales.
NLTK no lematiza realmente el español; su stemmer Snowball solo recorta sufijos.	Snowball es un stemmer basado en reglas fijas, no un lematizador basado en diccionario + gramática como spaCy.	Se descartó NLTK para esta tarea y se adoptó spaCy con modelos entrenados por idioma (es_core_news_sm, en_core_web_sm).	Justificación técnica documentada explícitamente en el encabezado del script de preprocesamiento.
El modelo pequeño (es_core_news_sm) no fusiona "campeona" con la forma canónica "campeón": ambas quedan como lemas separados en el corpus (19 y 15 apariciones respectivamente).	Limitación conocida de precisión de los modelos _sm de spaCy frente a _md/_lg, especialmente en variantes de género de sustantivos.	Se documentó como limitación aceptada del modelo pequeño en vez de parcharla manualmente con reglas ad hoc no generalizables.	Conteo verificado directamente sobre corpus_mundial2026_preprocesado.json: "campeón" (15), "campeona" (19), "campeonato" (12) coexisten como lemas distintos.
Riesgo de que términos de boilerplate editorial (créditos de foto, agencias) contaminaran el vocabulario temático.	Los artículos de noticias incluyen texto recurrente ajeno al tema (ej. "crédito", "Getty", "AFP") que no aporta valor para identificar temas.	Se amplió la lista base de stopwords de spaCy con una lista propia de términos deportivos/editoriales genéricos de bajo valor temático, por idioma.	Este filtrado inicial se reforzó y confirmó formalmente en la Sesión 6, donde se identificó y documentó explícitamente el boilerplate restante antes del clustering final.

Tomas de Decisiones Destacadas

Elegir spaCy sobre NLTK con evidencia técnica, no por preferencia personal

La decisión no fue "cuál librería conocemos mejor", sino una comparación explícita de cómo cada una maneja la lematización en español, documentando por qué el stemmer de NLTK introduce un riesgo real de fusionar palabras con significados distintos.

Elegir lematización sobre stemming pensando en el paso siguiente del pipeline

La justificación no se limitó a la calidad del preprocesamiento en sí, sino que se ancló explícitamente en cómo afectaría la Sesión 6 (TF-IDF/embeddings): preservar la forma canónica de la palabra da vectores semánticamente más limpios.

Documentar el error de lematización de género en vez de ocultarlo o parcharlo a mano

En lugar de forzar una corrección manual improvisada para "campeona"/"campeón" (que no generalizaría al resto del corpus), el equipo decidió cuantificar el error, documentarlo como limitación aceptada del modelo _sm, y dejar abierta la posibilidad de migrar a un modelo más grande si llegara a distorsionar los resultados de clustering — lo cual, verificado en la Sesión 6, no ocurrió de forma significativa.

Cuadro Comparativo: Decisiones de la IA vs. Decisiones del Equipo

Nota metodológica: las columnas contrastan la propuesta esperable —muchas veces la sugerida por la plantilla del curso o la primera opción de una IA generativa— frente a la decisión final del equipo, documentada en el script de preprocesamiento y en los metadatos del corpus, conforme a la metodología BRAI.

Problema abordado	Qué propuso / sugirió la IA	Qué aceptó el equipo	Qué rechazó el equipo y por qué (evidencia)
Qué librería usar para lematizar un corpus bilingüe.	Propuesta por defecto (la que sugiere la plantilla del curso para esta sesión): usar NLTK, la librería clásica de NLP enseñada primero en la mayoría de cursos introductorios.	Se aceptó que NLTK es una librería válida y bien documentada para tareas básicas de tokenización.	Se rechazó NLTK específicamente para lematización, con evidencia técnica explícita de que su stemmer Snowball en español no lematiza — solo recorta sufijos de forma agresiva — y puede fusionar palabras con significado distinto; se adoptó spaCy en su lugar.
Cómo tratar el error de lematización de género ("campeona" vs. "campeón").	Enfoque automático esperable: "arreglar" el error a mano con un diccionario de excepciones o reemplazos ad hoc para esa palabra específica.	Se aceptó cuantificar el error real contando ambas formas en el corpus preprocesado.	Se rechazó parcharlo manualmente: el equipo decidió documentarlo como limitación aceptada del modelo _sm en vez de introducir una regla ad hoc que no generalizaría a otras palabras con el mismo problema, priorizando transparencia sobre una solución cosmética.
Qué hacer con el marcador de truncamiento de NewsAPI dentro del texto de cada artículo.	Enfoque automático esperable: confiar en que el filtrado estándar de tokens cortos o stopwords neutralizaría ese patrón "por accidente", sin necesidad de tratarlo de forma especial.	Se aceptó que el corpus necesitaba una etapa de limpieza previa a la tokenización.	Se rechazó confiar en el filtrado genérico: el equipo identificó el patrón exacto del marcador ("... [+N chars]") como un artefacto propio de la API y lo eliminó explícitamente con expresiones regulares antes de tokenizar, en vez de esperar que el pipeline lo manejara de forma indirecta.