



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 8

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

1. Glosario de Términos Técnicos

Término	Definición
Pronóstico (forecasting)	Estimación de valores futuros de una serie a partir de su comportamiento histórico.
Holdout	Subconjunto de datos reservado para evaluar un modelo, que no participa en su entrenamiento.
MAE (Error Absoluto Medio)	Promedio de la diferencia absoluta entre el valor real y el valor pronosticado; entre menor, mejor.
RMSE (Raíz del Error Cuadrático Medio)	Métrica de error que penaliza más fuertemente los errores grandes que el MAE.
ARIMA	Modelo estadístico autorregresivo integrado de medias móviles, adecuado para series con tendencia.
Prophet	Librería de pronóstico (originalmente de Meta/Facebook) diseñada para series con tendencia y cambios de régimen ("changepoints").
LSTM (Long Short-Term Memory)	Arquitectura de red neuronal recurrente para datos secuenciales; requiere volúmenes de datos considerablemente mayores que los métodos estadísticos clásicos.
Sobreajuste (overfitting)	Cuando un modelo aprende el ruido específico de los datos de entrenamiento en vez del patrón general, y por eso falla al generalizar sobre datos nuevos.
Modelo baseline	Modelo simple usado como referencia mínima; cualquier modelo más sofisticado debe superarlo para justificar su uso.

2. Objetivo de la Sesión

Aplicar y comparar empíricamente distintos modelos de pronóstico (baseline, ARIMA, Prophet y un sustituto de red neuronal) sobre la serie diaria de cobertura mediática construida en la Sesión 7, con el fin de decidir con evidencia cuál modelo adoptar, en vez de asumir que el modelo más sofisticado es automáticamente el más adecuado.

3. Herramientas y Tecnologías Utilizadas

- Python 3.14
- statsmodels — modelado ARIMA
- prophet — modelado de series con tendencia y changepoints
- scikit-learn — MLPRegressor (sustituto de red neuronal) y métricas de evaluación
- pandas y matplotlib — manejo de datos y visualización
- Insumo previo: series_diarias.csv (Sesión 7)

4. Roadmap: Qué se Hizo

1. Se dividió la serie en un conjunto de entrenamiento (21 días, 10-30 de julio) y un conjunto de prueba u holdout (7 días, 31 de julio-6 de agosto), evaluando cada modelo únicamente contra datos que no vio durante el entrenamiento.
2. Se dejó explícitamente sin imputar el 27 de julio (la anomalía de captura ya identificada en la Sesión 7), que cae dentro del set de entrenamiento, para poder observar y documentar su efecto en vez de "corregir" los datos de forma silenciosa.
3. Se implementaron y evaluaron 5 modelos: naive (último valor), media móvil (ventana de 5 días), ARIMA (con búsqueda de orden por criterio AIC), Prophet, y un sustituto de red neuronal (MLPRegressor sobre ventana de rezagos).
4. Se documentó una restricción real de infraestructura: no fue posible instalar TensorFlow ni PyTorch en el entorno de trabajo por falta de espacio en disco (solo 3.2 GB libres); se sustituyó por MLPRegressor de scikit-learn, dejando constancia expresa de que no es una LSTM real, aunque comparte la propiedad relevante para la prueba (más parámetros que datos disponibles).
5. Se calcularon MAE y RMSE de cada modelo contra los 7 días reales del holdout.
6. Resultado: la media móvil (ventana=5) obtuvo el menor error (MAE=1.54, RMSE=1.88), superando a ARIMA (MAE=1.68), al pronóstico naive (MAE=1.71), a Prophet (MAE=3.14) y, por un margen amplio, al sustituto de red neuronal (MAE=7.77).
7. Se documentó el rechazo explícito de los tres modelos considerados "más sofisticados" por el temario del curso, con evidencia cuantitativa y no por intuición o complejidad percibida.
8. Se interpretó el resultado: el sustituto de red neuronal extrapoló una tendencia ascendente inexistente (síntoma clásico de sobreajuste con pocos datos de entrenamiento), mientras que Prophet sobreestimó de forma sistemática al interpretar parte del ruido de la cola como tendencia real.

5. Problemas Encontrados y Soluciones

Problema	Causa	Solución aplicada
Imposible instalar TensorFlow/PyTorch para una LSTM real	Espacio en disco agotado en el entorno de trabajo (solo 3.2 GB libres disponibles).	Se sustituyó por MLPRegressor de scikit-learn (ya disponible), documentando explícitamente la sustitución y su justificación en el propio script.
Prophet configurado con estacionalidad semanal por defecto	Con solo 21 días de entrenamiento (3 semanas) no hay evidencia estadística suficiente para estimar un patrón semanal confiable.	Se desactivaron explícitamente la estacionalidad diaria, semanal y anual del modelo.
ARIMA requiere elegir un orden (p, d, q)	La serie es demasiado corta para una búsqueda automática exhaustiva tipo auto_arima.	Se probó un conjunto acotado de órdenes razonables dada la tendencia observada, y se seleccionó el de menor AIC.
Riesgo de que la anomalía del 27 de julio distorsione el entrenamiento	Ese día cae dentro del set de entrenamiento y su valor (0) no refleja la realidad.	Se dejó sin imputar intencionalmente, documentando el riesgo, en vez de alterar los datos sin dejar rastro de la decisión.

6. Tomas de Decisiones Destacadas

- No asumir automáticamente que un modelo más complejo (Prophet, red neuronal) es superior a uno simple — probar todos empíricamente y aceptar el resultado, sea cual sea.
- Usar un modelo baseline obligatorio (naive y media móvil) como piso mínimo de comparación, sin el cual no habría contra qué medir a los demás modelos.
- Ser transparente sobre la sustitución técnica de LSTM por restricción de infraestructura, documentándola en el propio código, en vez de omitir el resultado o presentar el sustituto como si fuera el modelo original.
- Adoptar el modelo más simple (media móvil) como resultado final del proyecto para esta serie, pese a que el temario del curso sugiere técnicas más avanzadas — la decisión se basa en desempeño medido, no en la complejidad aparente del método.

7. Comparación: Decisiones de la IA vs. Decisiones del Equipo Humano

La metodología BRAI del curso exige documentar explícitamente qué propuso la Inteligencia Artificial frente a cada problema, y qué decidió finalmente el equipo humano — incluyendo los casos en que ambas coincidieron y los casos en que no.

Aspecto / Problema	Qué propuso la IA	Qué decidió el equipo	Resultado
Qué modelo de pronóstico usar	Propuso probar los 5 candidatos de forma empírica (con un holdout real) en vez de elegir uno de antemano por su reputación o complejidad.	Aceptó la metodología de comparación propuesta y delegó la ejecución técnica completa en la IA.	Modelo final elegido con evidencia cuantitativa (media móvil), no por cuál "suena" más avanzado.
Sustitución de LSTM por restricción de disco	Propuso usar MLPRegressor como sustituto documentado, en vez de detener el trabajo o simular un resultado falso de LSTM.	Aceptó la sustitución para priorizar avanzar dentro del tiempo disponible del entregable.	Evidencia suficiente para la conclusión, con la limitación de infraestructura declarada con transparencia.
Tratamiento del 27 de julio en el set de entrenamiento	Propuso dejar el dato sin imputar, para que su efecto fuera observable y documentable en vez de oculto.	Validó el criterio de no alterar los datos sin justificación registrada.	El efecto de la anomalía queda trazable en los resultados, en vez de desaparecer silenciosamente.

8. Evidencia Visual

