



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 9

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

1. Glosario de Términos Técnicos

Término	Definición
Anomalía / outlier	Observación que se desvía significativamente del patrón general de los datos.
Z-score	Medida estadística de cuántas desviaciones estándar se aleja un valor respecto de la media de la serie.
Isolation Forest	Algoritmo de detección de anomalías basado en árboles de decisión, que aísla las observaciones atípicas con menos particiones que las observaciones normales.
Anomalía de captura	Caso en que la ausencia de datos se debe a una falla del proceso de recolección, y no a la ausencia real del fenómeno que se está midiendo.
Punto ciego (blind spot)	Limitación de un método que le impide detectar cierto tipo de problema, incluso cuando el método está funcionando correctamente dentro de su propio marco de referencia.
Verificación cruzada con fuente externa	Contrastar un hallazgo contra una fuente de datos independiente antes de darlo por válido.
Contaminación (Isolation Forest)	Parámetro que define la proporción esperada de observaciones anómalas en el conjunto de datos.

2. Objetivo de la Sesión

Aplicar técnicas de detección de anomalías (Z-score e Isolation Forest) sobre la serie diaria de cobertura mediática, contrastando explícitamente los resultados contra la anomalía de captura del 27 de julio ya confirmada en la Sesión 7, para evaluar si los métodos estadísticos estándar son suficientes por sí solos para detectar este tipo de problema.

3. Herramientas y Tecnologías Utilizadas

- Python 3.14
- scikit-learn — IsolationForest
- pandas y numpy — cálculo de Z-score y manejo de datos
- matplotlib — visualización de anomalías
- Insumo previo: series_diarias.csv (Sesión 7)

4. Roadmap: Qué se Hizo

1. Se cargó la serie diaria añadiendo variables adicionales: día de la semana, distribución por idioma (es/en) y distribución por cluster temático (Sesión 6).
2. Se calculó el Z-score univariado sobre el volumen total diario, con un umbral de $|z| > 2.0$ para marcar anomalías.
3. Se aplicó Isolation Forest de forma multivariada, usando 7 variables (volumen total, idioma, día de la semana y los 3 clusters temáticos), con un parámetro de contaminación del 15%.
4. Se diseñó explícitamente una verificación cruzada como prueba de validación del método: ¿el 27 de julio —ya confirmado como anomalía de captura en la Sesión 7— es detectado por alguna de las dos técnicas?
5. Resultado principal: el 19 y el 20 de julio (final del Mundial) fueron detectados como anomalías por ambos métodos, con z-scores de 2.14 y 3.04 respectivamente — consistente con un evento real y verificable externamente.
6. Resultado secundario, más relevante: el 27 de julio NO fue detectado como anomalía por ninguno de los dos métodos (z-score de apenas -0.96, dentro del rango normal).
7. Se documentó la conclusión sin forzar el resultado: la detección de anomalías estadística tiene un punto ciego estructural para fallas de recolección que se camuflan dentro de valores ya bajos, propios de la cola de la serie.
8. Isolation Forest marcó además 3 días adicionales no detectados por Z-score (11, 15 y 17 de julio), que quedan como línea de trabajo abierta para revisión cualitativa por el equipo (posible mezcla atípica de idioma o de cluster temático).

5. Problemas Encontrados y Soluciones

Problema	Causa	Solución aplicada
El 27 de julio, ya sabido como anómalo, no aparece marcado por ninguna de las dos técnicas	Para esas fechas la serie ya está naturalmente aplanada (0-6 artículos/día); un 0 adicional no se distingue estadísticamente de un día real de baja actividad.	Se documenta el resultado tal cual, como un hallazgo válido sobre las limitaciones del método, en vez de ajustar artificialmente los parámetros hasta forzar su detección.
Isolation Forest marca 3 días adicionales (11, 15, 17 jul) sin causa evidente a simple vista	Al ser un modelo multivariado, puede reaccionar a combinaciones no obvias (por ejemplo, una proporción atípica de idioma o de cluster ese día), difíciles de explicar solo mirando el total diario.	Se deja registrado como línea abierta para revisión cualitativa del equipo, en vez de inventar una interpretación sin evidencia que la respalde.
Elegir el parámetro de contaminación de Isolation Forest	No existe una regla fija; un valor mal justificado puede sobre- o sub-detectar anomalías de forma arbitraria.	Se fijó en 15% (aproximadamente 4 de 28 días) como valor razonable dado que la serie tiene un evento dominante conocido, documentando explícitamente que es un supuesto de diseño y no una verdad absoluta.

6. Tomas de Decisiones Destacadas

- Diseñar la sesión explícitamente para poner a prueba el método contra un caso ya conocido (27 de julio), en lugar de solo "correr el algoritmo y ver qué sale" — una verificación intencional, no exploratoria.
- Documentar honestamente que el método NO detectó lo que ya se sabía que debía detectar, en vez de omitir ese resultado o ajustar el umbral hasta forzar la detección, lo cual habría equivalido a manipular la evidencia.
- Dejar abiertos, sin especular, los 3 días adicionales marcados por Isolation Forest como trabajo pendiente del equipo, en vez de inventar una interpretación sin sustento.

7. Comparación: Decisiones de la IA vs. Decisiones del Equipo Humano

La metodología BRAI del curso exige documentar explícitamente qué propuso la Inteligencia Artificial frente a cada problema, y qué decidió finalmente el equipo humano — incluyendo los casos en que ambas coincidieron y los casos en que no.

Aspecto / Problema	Qué propuso la IA	Qué decidió el equipo	Resultado
¿Los métodos estadísticos detectarían por sí solos el problema del 27 de julio?	Propuso diseñar la verificación cruzada explícitamente como prueba de validación, anticipando —como hipótesis razonada, no como certeza— que probablemente el método no lo detectaría.	Aceptó el diseño de la prueba tal cual, sin pedir ajustar el umbral para forzar artificialmente la detección del 27 de julio.	Se documentó honestamente una limitación real del método (punto ciego), lo cual tiene más valor académico que un resultado "perfecto" logrado ajustando parámetros a modo.
Interpretación de los 3 días adicionales marcados por Isolation Forest	Propuso reportar los días marcados sin especular sobre la causa exacta ante la falta de evidencia adicional inmediata.	Decidió dejar la revisión manual de esos días como trabajo pendiente del equipo, en vez de exigir una respuesta inmediata sin sustento.	Trabajo abierto y transparente, documentado como pendiente en vez de cerrado artificialmente.

8. Evidencia Visual

