



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 10

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

Glosario de Términos Técnicos

Término	Definición
robots.txt	Archivo de texto estándar en la raíz de un sitio web que declara qué rutas pueden o no ser accedidas por robots/crawlers automatizados. Es una convención voluntaria, no una ley.
User-Agent	Cadena de texto que identifica al programa que hace una petición HTTP (navegador, script, bot). Los sitios lo usan para permitir o bloquear ciertos clientes.
Rate limiting	Restricción que aplica un servidor para limitar cuántas peticiones puede recibir de un mismo origen en un periodo de tiempo, como defensa contra abuso.
HTTP 403 Forbidden	Código de respuesta HTTP que indica que el servidor entendió la petición pero se niega a autorizarla.
TLS fingerprint	Patrón identificable en cómo un cliente establece una conexión cifrada (TLS/SSL), usado por sistemas anti-bot (ej. Cloudflare) para distinguir navegadores reales de scripts automatizados, incluso si los headers HTTP se falsifican.
Web scraping ético	Práctica de extracción automatizada de datos de sitios web que respeta robots.txt, no sobrecarga el servidor (rate limiting propio) y se identifica honestamente.
API REST	Interfaz de programación que expone datos/funciones de un servicio a través de peticiones HTTP estructuradas (GET, POST, etc.), en contraste con el scraping de HTML.
JWT (JSON Web Token)	Estándar de token de autenticación que permite a un cliente demostrar su identidad ante una API sin reenviar usuario/contraseña en cada petición.

Objetivo de la Sesión

Formalizar y auditar éticamente el scraping ya realizado en la Sesión 2 (Fase de selección de datos) sobre Transfermarkt, FBref y worldcup26.ir, cerrando el punto que quedó pendiente en su momento: la verificación explícita de robots.txt de cada fuente, contrastada contra las rutas reales que se utilizaron en el proyecto.

Decisión metodológica (BRAI): en lugar de generar minería web nueva desde cero -que hubiera duplicado esfuerzo ya invertido-, se decidió reciclar y formalizar la evidencia de scraping ya producida, agregando únicamente la verificación ética que faltaba.

Herramientas y Tecnologías Utilizadas


- Python 3.14 (entorno local del equipo)
- Librería requests (descarga de robots.txt)
- Módulo urllib.robotparser (interpretación de reglas Disallow/Allow)
- PowerShell (Windows) para la ejecución de scripts
- Claude (IA asistente) para diagnóstico de errores de entorno y diseño del script de verificación

Roadmap: Qué se Hizo

1. Se definió la decisión metodológica de reciclar evidencia de la Sesión 2 en vez de scrapear una fuente nueva.
2. Se intentó verificar los 3 robots.txt directamente desde el entorno de Claude — resultado: bloqueado por restricciones propias del entorno de la IA.
3. Se diseñó el script `verificar_robots_txt.py`, con las rutas reales scrapeadas en Sesión 2 embebidas como casos de prueba.
4. Se entregó el script para ejecución local, junto con un checklist de ética de scraping (identificación en User-Agent, ritmo de peticiones, acceso sin login de terceros, datos sensibles).
5. Se resolvieron dos errores de entorno de Windows/Python que impidieron la primera ejecución (launcher de pip roto, sintaxis de PowerShell).
6. Se ejecutó el script exitosamente, obteniendo veredictos reales para las 3 fuentes.
7. Se actualizó el checklist con los resultados reales y se documentó el hallazgo adicional del bloqueo de FBref a nivel de robots.txt.

Problemas Encontrados y Cómo se Resolvieron

Problema encontrado	Cómo se resolvió
La verificación de robots.txt no pudo hacerse desde el entorno de Claude: Transfermarkt devolvió SITE_BLOCKED (bloqueo del propio proveedor de herramientas de la IA) y FBref/worldcup26.ir fueron rechazados por política de la herramienta (solo permite acceder a URLs ya vistas en una búsqueda previa).	Se diseñó el script verificar_robots_txt.py para ejecutarse en la máquina local del equipo (VS Code), replicando el mismo patrón ya usado en la Sesión 7 con verificar_dias_cero.py, donde ciertas verificaciones solo son posibles con acceso de red sin restricciones.
Al instalar dependencias con pip, apareció el error "Fatal error in launcher": el ejecutable pip.exe apuntaba a una instalación de Python 3.13 que ya no existía en el sistema.	Se reemplazó el uso de pip.exe directo por python -m pip, que invoca pip como módulo del intérprete realmente activo (Python 3.14), evitando depender de un launcher desactualizado.
Al invocar python.exe con su ruta completa entre comillas desde PowerShell, se produjo un error de sintaxis ("Token inesperado").	Se identificó que PowerShell requiere el operador de invocación & antes de una ruta entre comillas para tratarla como comando ejecutable, no como una cadena de texto.
El propio archivo robots.txt de FBref devolvió HTTP 403, no solo las páginas de datos ya conocidas como bloqueadas desde la Sesión 2.	Se documentó como evidencia adicional (no solo teórica) de que el bloqueo de FBref ocurre a nivel de conexión (fingerprint TLS de Cloudflare), reforzando con datos nuevos la decisión de rechazo ya tomada en la Sesión 2.



Tomas de Decisiones Destacadas

- Reciclar la evidencia de scraping ya producida en la Sesión 2 (Transfermarkt, FBref, worldcup26.ir) en lugar de generar minería web nueva desde cero, priorizando no duplicar trabajo ya validado.
- Ejecutar la verificación de robots.txt en la máquina local del equipo en vez de forzar una alternativa dentro del entorno restringido de la IA.
- Aceptar Transfermarkt y worldcup26.ir como fuentes con scraping/consumo de API explícitamente permitido según robots.txt, sin necesidad de cambiar de fuente.
- Mantener el rechazo ya decidido de FBref en la Sesión 2, ahora reforzado con evidencia adicional de bloqueo total (incluso al robots.txt mismo).

Cuadro Comparativo: Decisiones de la IA vs. Decisiones del Equipo Humano

Problema / Decisión	Propuesta de la IA	Decisión / Acción del equipo humano
¿Es viable verificar la legalidad/ética de las 3 fuentes ya scrapeadas?	Diseñar un script de verificación automática de robots.txt y contrastarlo contra las rutas reales usadas en la Sesión 2. Intentar ejecutarlo primero desde el propio entorno de la IA.	Ejecutar el script en la máquina local (la IA no pudo hacerlo por restricciones de red propias de su entorno). Confirmar y compartir los resultados reales obtenidos.
Errores de entorno de Python/pip en Windows	Diagnosticar la causa del error del launcher y proponer el comando alternativo (python -m pip) y la corrección de sintaxis de PowerShell (operador &).	Aplicar las correcciones sugeridas y confirmar que el entorno quedó funcional para continuar con el resto de la sesión.