



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

MINERÍA DE DATOS

Grupo: 09_02

PROYECTO INTEGRADOR SESIÓN 11

Nombre del Alumno:

Alvaro Lechuga Vecino

Teodoro Gómez Santillan

Alan Khalid Licona Ramírez

Glosario de Términos Técnicos

Término	Definición
Índice invertido	Estructura de datos que mapea cada término del vocabulario a la lista de documentos donde aparece (y su frecuencia), permitiendo búsquedas rápidas sin recorrer todo el corpus.
TF-IDF (Term Frequency - Inverse Document Frequency)	Método de ponderación que mide qué tan importante es un término en un documento respecto a su frecuencia en todo el corpus; términos comunes en todos los documentos pesan menos.
BM25	Función de ranking probabilística usada en motores de búsqueda de producción, similar a TF-IDF pero con saturación de frecuencia de término y normalización por longitud de documento (parámetros k_1 y b).
Lematización / Lema	Proceso de reducir una palabra a su forma canónica de diccionario (ej. "jugando" -> "jugar"); un lema es el resultado de ese proceso.
Similitud coseno	Medida que calcula el coseno del ángulo entre dos vectores, usada para comparar qué tan similares son un documento y una consulta en un espacio vectorial.
Corpus	Conjunto completo de documentos de texto sobre el que se realiza el análisis; en este proyecto, 330 artículos de noticias sobre el Mundial 2026.
Ranking	Orden en el que un motor de búsqueda presenta los resultados, típicamente de mayor a menor relevancia calculada.

Objetivo de la Sesión

Construir un índice invertido sobre el corpus preprocesado (Sesión 5: 330 artículos, 10,518 lemas) y comparar TF-IDF vs. BM25 como técnicas de recuperación, verificando con evidencia empírica si la limitación estructural que hizo fracasar a TF-IDF en clustering temático (Sesión 6) se repite en la tarea de indexación.

Punto BRAI central: el fracaso de una técnica en una tarea (clustering) no implica automáticamente su fracaso en otra tarea distinta (indexación) que tiene requisitos diferentes — clustering necesita que los vectores se separen entre sí, indexación solo necesita discriminar contra una consulta puntual. Esta hipótesis se probó, no se asumió.

Herramientas y Tecnologías Utilizadas


- Python 3.x
- scikit-learn (TfidfVectorizer, cosine_similarity)
- rank_bm25 (implementación de BM25Okapi)
- pandas (manejo de resultados tabulares)
- Corpus preprocesado de la Sesión 5
(corpus_mundial2026_preprocesado.json)

Roadmap: Qué se Hizo

- 1. Se planteó la pregunta central: ¿el fracaso de TF-IDF en clustering se repite en indexación?
- 2. Se cargó el corpus preprocesado (330 artículos, 10,518 lemas).
- 3. Se construyó el índice invertido (3,252 términos únicos).
- 4. Se calculó la matriz TF-IDF (330 documentos x 3,233 términos).
- 5. Se construyó el modelo BM25 con parámetros por defecto ($k_1=1.5$, $b=0.75$).
- 6. Se definieron 10 consultas de prueba en español e inglés, de distintos tipos (nombres propios, conceptos, eventos).
- 7. Se ejecutaron las consultas en ambos motores y se compararon los resultados top-5.
- 8. Se documentó el hallazgo principal (8/10 coincidencias en el top-1) y la limitación de tokenización de consultas.

Problemas Encontrados y Cómo se Resolvieron

Problema encontrado	Cómo se resolvió
Existía el riesgo de asumir que TF-IDF fallaría en indexación igual que falló en clustering (Sesión 6, silhouette casi nulo), sin comprobarlo.	Se probó empíricamente en vez de generalizar sin evidencia (principio BRAI): se ejecutaron ambas técnicas sobre el corpus real y se compararon resultados, confirmando que el fracaso de clustering NO se repite en indexación (8/10 coincidencias en el top-1).
La librería rank_bm25 no estaba instalada en el entorno de trabajo.	Se instaló sin incidentes vía pip antes de construir el índice BM25.
Las consultas de prueba se tokenizaron con un simple <code>.lower().split()</code> , sin pasar por el mismo pipeline de lematización spaCy que procesó el corpus.	Se documentó como limitación real: genera que consultas en inglés recuperen artículos en español solo por tokens compartidos (ej. "world", "cup"), no por comprensión real del idioma. Se recomendó lematizar la consulta en la Sesión 12.
2 de las 10 consultas de prueba mostraron discrepancia en el documento top-1 entre TF-IDF y BM25.	Se investigó cada caso: uno resultó ser un empate técnico de score en BM25 (desempatado distinto por cada algoritmo), y el otro un falso negativo por comparar doc_id exacto en vez de detectar que eran artículos duplicados de la misma fuente.



Tomas de Decisiones Destacadas

- No asumir que el rechazo de TF-IDF en la Sesión 6 (clustering) aplica automáticamente a la Sesión 11 (indexación) — son tareas distintas con requisitos distintos, y se decidió probarlo con evidencia antes de aceptar o descartar la técnica.
- Usar los lemas del corpus (no el texto crudo) para construir tanto el índice invertido como las matrices TF-IDF/BM25, manteniendo consistencia con el pipeline ya validado en la Sesión 5.
- Documentar abiertamente la inconsistencia de tokenización de las consultas como limitación reconocida, en vez de presentar el resultado como si no tuviera matices.

Cuadro Comparativo: Decisiones de la IA vs. Decisiones del Equipo Humano

Problema / Decisión	Propuesta de la IA	Decisión / Acción del equipo humano
¿TF-IDF debe descartarse en esta sesión, dado que falló en la Sesión 6?	Cuestionar la generalización automática del rechazo previo y proponer probar TF-IDF y BM25 con evidencia real sobre el corpus antes de decidir.	Aceptar la propuesta de no generalizar sin evidencia y solicitar la ejecución real sobre el corpus preprocesado para confirmar o refutar la hipótesis.
Elegir qué texto usar para indexar (lemas vs. texto crudo)	Recomendar mantener los lemas para preservar consistencia metodológica con el pipeline de preprocesamiento ya validado en Sesión 5.	Aceptar la recomendación sin objeciones, priorizando la trazabilidad del pipeline sobre una posible mejora marginal de resultados.